

Многопоточное и/или консистентное чтение из реляционных источников данных в федеративных системах

Виталий Исаев

Яндекс, YDB



**Data
Internals X**
2025

МойОфис: объектное хранилище проекта Mailion


Яндекс: YDB, Yandex Query

Go / C++ / Python




Назначение федеративных систем

Ландшафт федеративных систем




Ландшафт федеративных систем

5



Ландшафт федеративных систем

6



- **Федеративные запросы** адресуются к внешним источникам данных
- **Оперативный анализ без перемещения данных**

Ландшафт федеративных систем

7

 mongoDB


Parquet


S3

Columnar

Document-oriented

Time series

 Prometheus



MySQL

Relational

KV

 redis

Federated System

User



YDB



Greenplum




DuckDB



ClickHouse

Ландшафт федеративных систем

8




Сценарий №1: миграция данных

9

INSERT INTO
columnar ...

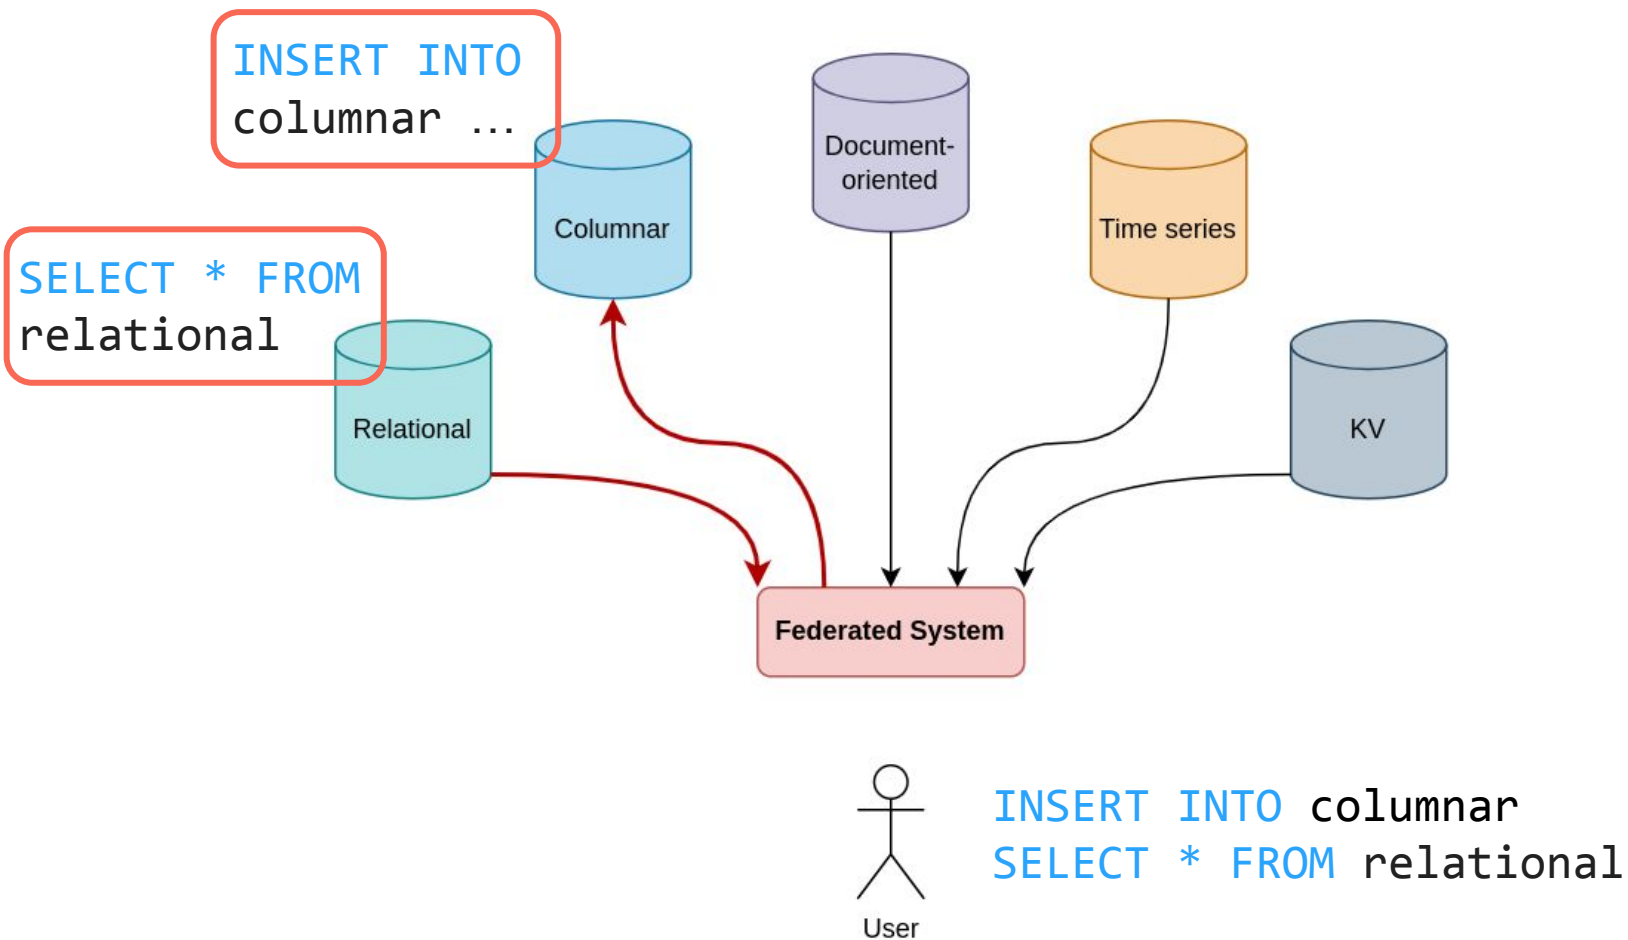
SELECT * FROM
relational



INSERT INTO columnar
SELECT * FROM relational


Сценарий №1: миграция данных

10




Сценарий №2: консолидация данных

11



Федеративные системы и распределённые СУБД

12



Чтение из реляционных СУБД

Свойства:

Чтение из реляционных СУБД

Свойства:

- масштабируемость:
 - чтение в несколько потоков;
 - чтение из разных инстансов распределённой СУБД.

Чтение из реляционных СУБД

Свойства:

- масштабируемость:
 - чтение в несколько потоков;
 - чтение из разных экземпляров распределённой СУБД.
- консистентность: все потоки работают с одним состоянием таблицы.

YDB как федеративная система

Коротко о YDB

Основное:

- СУБД класса distributed SQL
- OLTP (row tables)
- OLAP (column tables)
- On-prem + cloud



YDB

Основное:

- СУБД класса distributed SQL
- OLTP (row tables)
- OLAP (column tables)
- On-prem + cloud




YDB

Федеративные возможности:

- Движок обработки федеративных запросов
- Источник данных для других федеративных систем


YDB Federated Query: on-prem-инсталляция

19




YDB Federated Query: on-prem-инсталляция

20




Источники с прямым доступом

21




Источники с доступом через коннектор

22



Источники с доступом через коннектор

23



Облачный сервис Yandex Query

24

Yandex Cloud

Yandex Query Control Plane

Pod 1

Pod 2


Pod 3

Pod 4

Pod 5

Pod ...

Serverless YDB



Connectors

Pod 1

Pod 2

Pod 3

Pod 4

Pod 5

Pod ...

Yandex Cloud Logging

Yandex Object Storage

Yandex Monitoring

Yandex Managed Databases



User

Облачный сервис Yandex Query

25

Yandex Cloud

Yandex Query Control Plane

Pod 1

Pod 2


Pod 3

Pod 4

Pod 5

Pod ...

Serverless YDB



Connectors

Pod 1

Pod 2

Pod 3

Pod 4

Pod 5

Pod ...

Yandex Cloud Logging

Yandex Object Storage

Yandex Monitoring

Yandex Managed Databases



User

Облачный сервис Yandex Query

26

Yandex Cloud

Yandex Query Control Plane

Pod 1

Pod 2


Pod 3

Pod 4

Pod 5

Pod ...

Serverless YDB



Connectors

Pod 1

Pod 2

Pod 3

Pod 4

Pod 5


Pod ...

Yandex Cloud Logging

Yandex Object Storage

Yandex Monitoring

Yandex Managed Databases




User

```
SELECT * FROM pg JOIN mysql
ON pg.id = mysql.id
```


Облачный сервис Yandex Query

27




Облачный сервис Yandex Query


28



Многопоточное чтение

Федеративные системы — MPP-системы






Split — фрагмент таблицы и “единица параллелизма” для MPP-системы.

1 split == entire table


32

Federated System

External table



1 split == 1 partition




ORACLE




33

Federated System

External table



1 split == 1 partition




ORACLE



34

Federated System

External table



N
threads

x

M
tasks

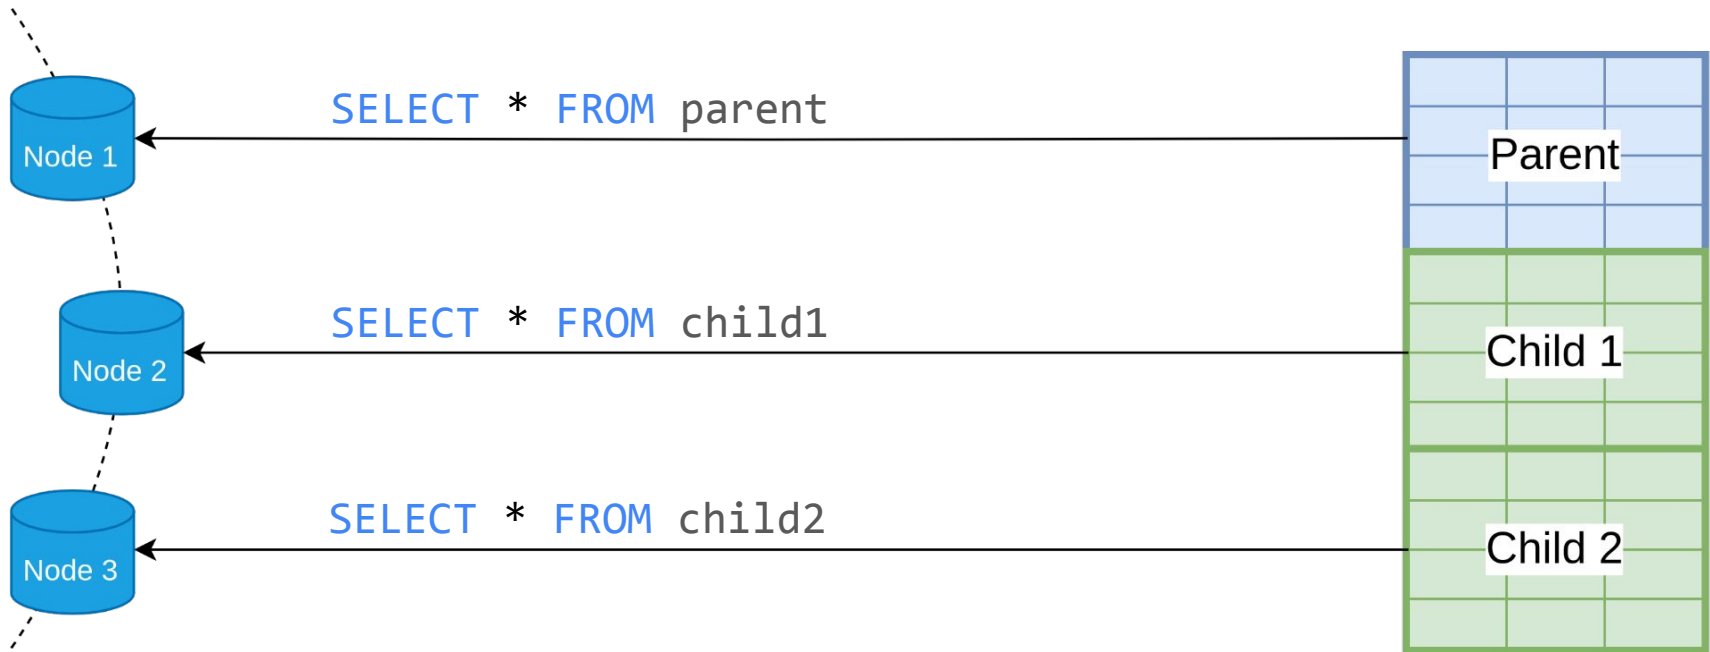
1 split == 1 partition



35


Federated System

External table




1 split == 1 segment

Federated System



External table




1 split == 1 segment

А если у таблицы нет партиций?


1 split == 1 row range

38

Federated System



External table




1 split == 1 primary key range

39

Federated System

External table




$$RangeSize = \frac{PK_{max} - PK_{min}}{N}$$

1 split == 1 primary key range

40

Federated System

External table




$$RangeSize = \frac{PK_{max} - PK_{min}}{N}$$


1 split == 1 key range

41

Uniform




Exponential



1 split == 1 key range



42




```
CREATE TABLE t (id SERIAL PRIMARY KEY);
```

1 split == 1 key range



43




```
CREATE TABLE t (id SERIAL PRIMARY KEY);
```

1 split == hash(key)



Federated System



External table


PK		
0		
1		
2		
3		
4		
5		
6		
7		
8		
9		
10		
11		

1 split == hash(key)



45

Federated System



External table

PK		
0		
1		
2		
3		
4		
5		
6		
7		
8		
9		
10		
11		

1 split == 1 page range




DuckDB



46

Federated System

External table



Page 0
...
Page 999
Page 1000
...
Page 1999
Page 2000
...
Page 2999

Источник: [Querying Postgres Tables Directly From DuckDB](#)

1 split == 1 page range




DuckDB



47

Federated System


External table



Источник: [Querying Postgres Tables Directly From DuckDB](#)


Yandex Query: масштабирование чтения

48




Yandex Query: масштабирование чтения

49




Yandex Query: масштабирование чтения

50




Yandex Query: масштабирование чтения




Yandex Query: масштабирование чтения

52




Massively parallel reading from external YDB




Yandex Query: масштабирование чтения

53




Massively parallel reading from external YDB




Yandex Query: масштабирование чтения

54



Massively parallel reading from external YDB



Split в различных системах

55

Federated system	Источник				
	PostgreSQL	Greenplum	MySQL	ClickHouse	YDB
Trino	entire table				-
Cedrus Data	entire table	segment	entire table		-
AWS Athena	partition				-
Greenplum PXF	key range				-
ClickHouse	entire table			partition	-
DuckDB	page range	-	entire table	-	-
YDB	key range	entire table			partition (column tables)

Многопоточное консистентное чтение

Минимальные требования:

- MVCC
- поддержка уровня изоляции
`SNAPSHOT ISOLATION` /
`REPEATABLE READ`
- **экспорт:** один и тот же
снелшот в нескольких
транзакциях

Оптимально:

- один и тот же снелшот в
несколькох транзакциях **на
разных узлах источника**

Распределённость:

- локальные снепшоты,
доступные только на мастере
- глобальные снепшоты,
доступные на всех узлах
кластера СУБД

Распределённость:

- локальные снепшоты,
доступные только на мастере
- глобальные снепшоты,
доступные на всех узлах
кластера СУБД

Отражение в API СУБД:

- экспортируемые снепшоты,
потенциально разделяемые
между транзакциями
- неэкспортируемые снепшоты,
недоступные клиенту

Многопоточное консистентное чтение из классических OLTP СУБД

Federated System

Node 1

Node 2

Node 3

External Data Source

Node 1

Node 2

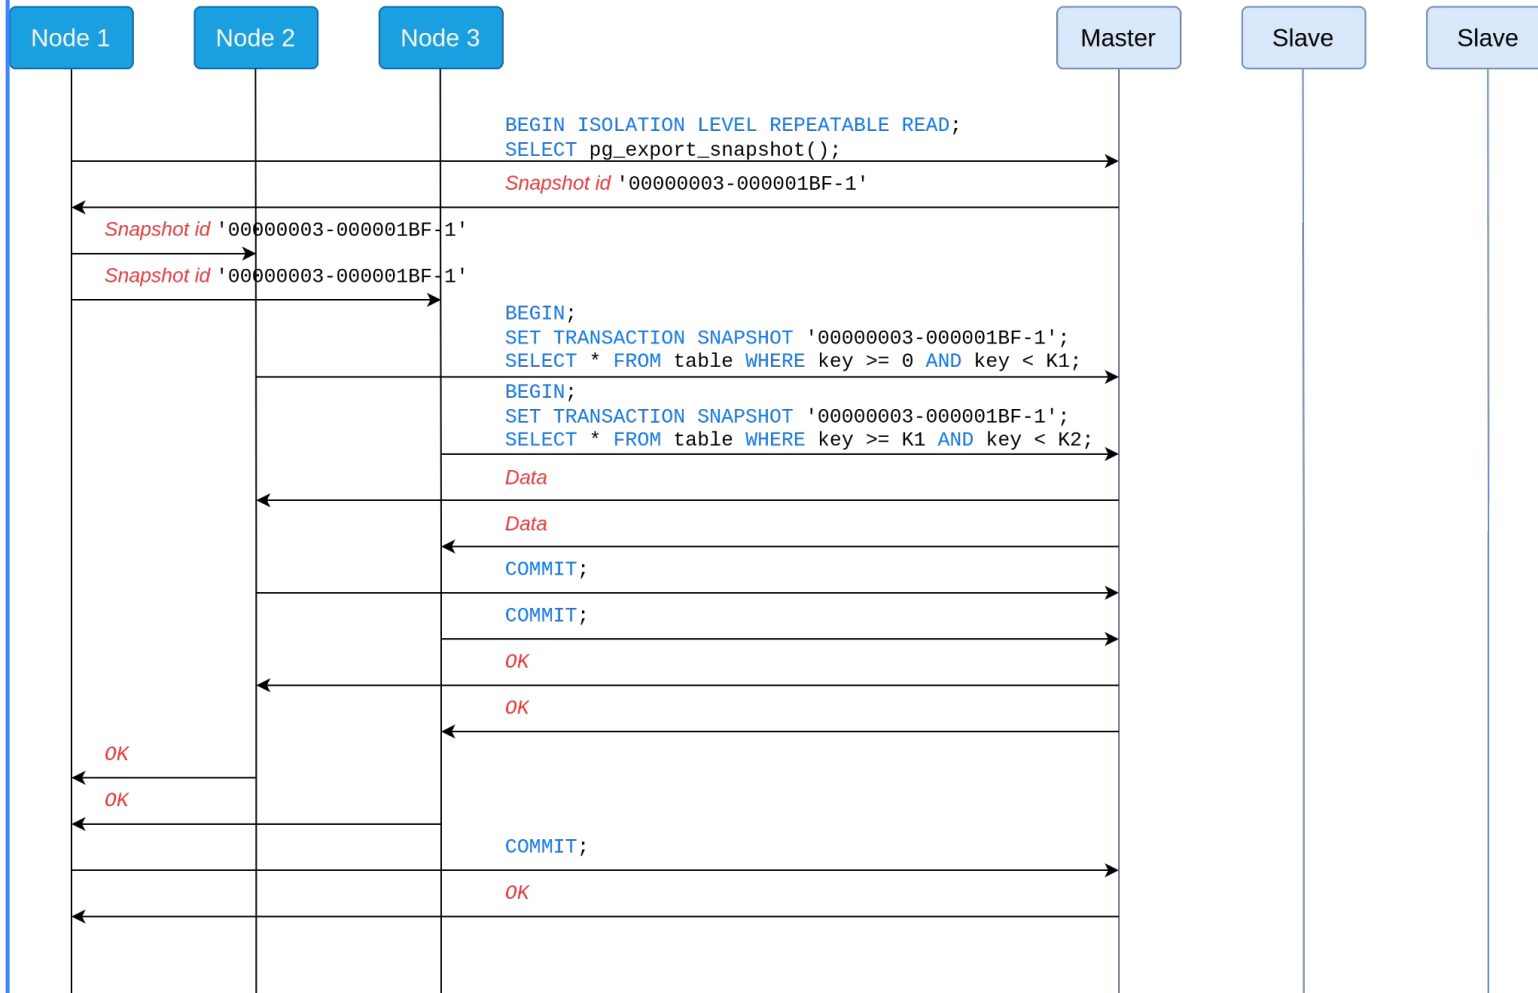
Node 3

Federated System

PostgreSQL



62




Federated System

PostgreSQL



63



Node 1

Node 2

Node 3

Master

Slave

Slave

```
BEGIN ISOLATION LEVEL REPEATABLE READ;  
SELECT pg_export_snapshot();  
  
Snapshot id '00000003-000001BF-1'
```

Snapshot id '00000003-000001BF-1'

Snapshot id '00000003-000001BF-1'

```
BEGIN;  
SET TRANSACTION SNAPSHOT '00000003-000001BF-1';  
SELECT * FROM table WHERE key >= 0 AND key < K1;
```

```
BEGIN;  
SET TRANSACTION SNAPSHOT '00000003-000001BF-1';  
SELECT * FROM table WHERE key >= K1 AND key < K2;
```

Data

Data

COMMIT;

COMMIT;

OK

OK

OK

OK

OK

OK

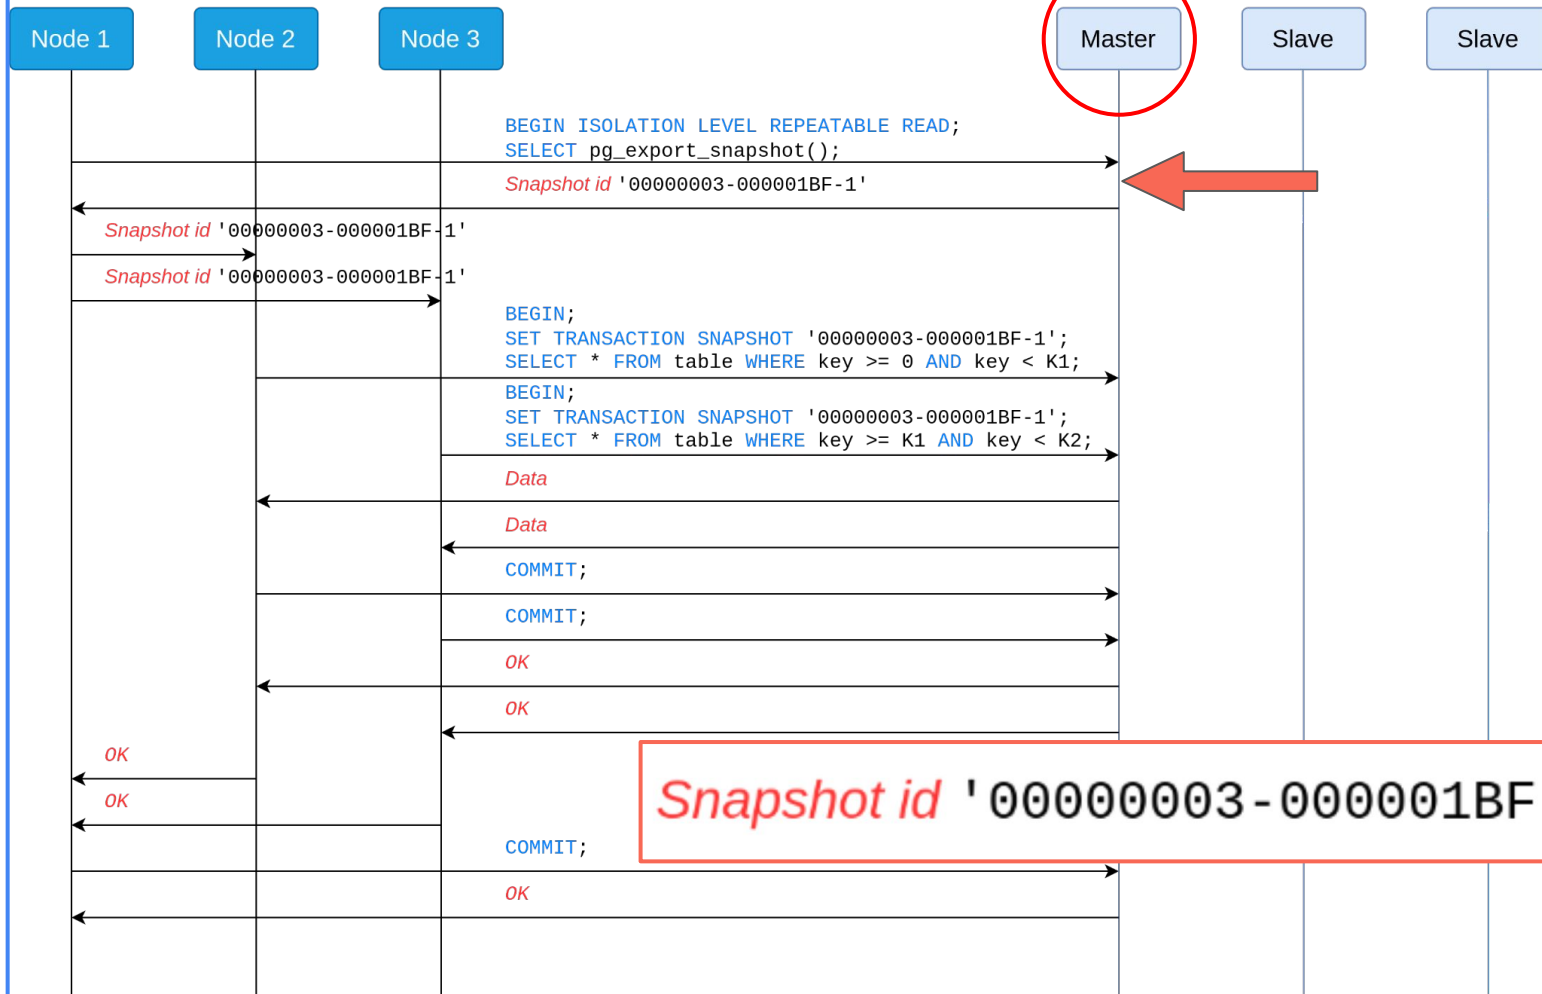
```
BEGIN ISOLATION LEVEL REPEATABLE READ;  
SELECT pg_export_snapshot();
```

Federated System

PostgreSQL



64

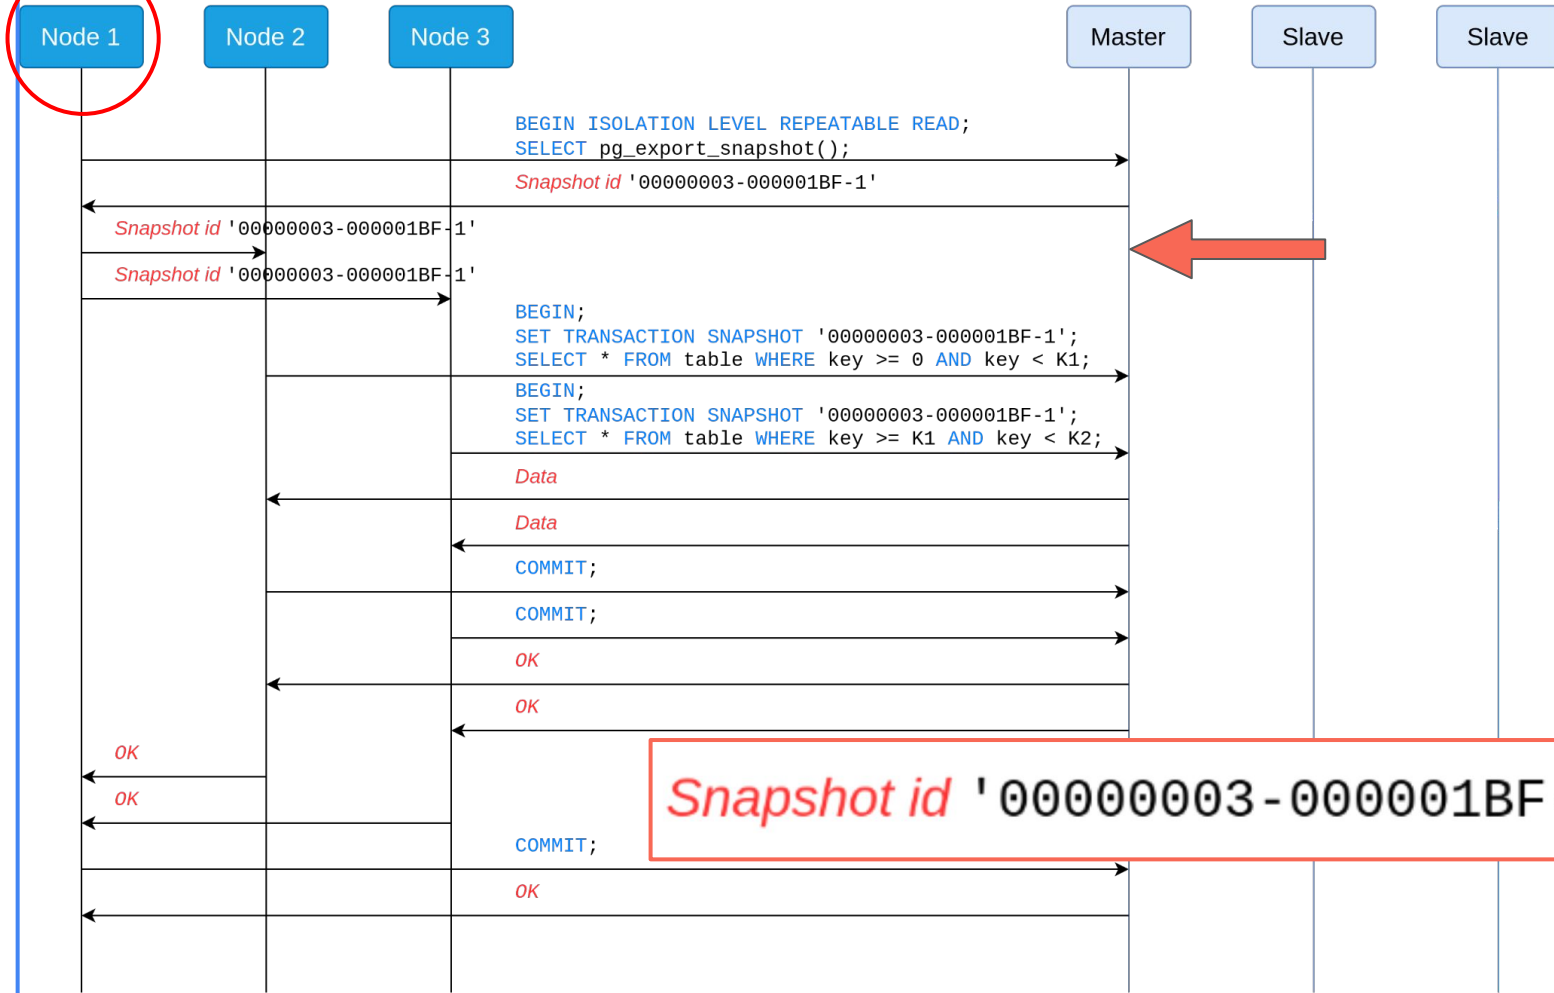


Federated System

PostgreSQL



65



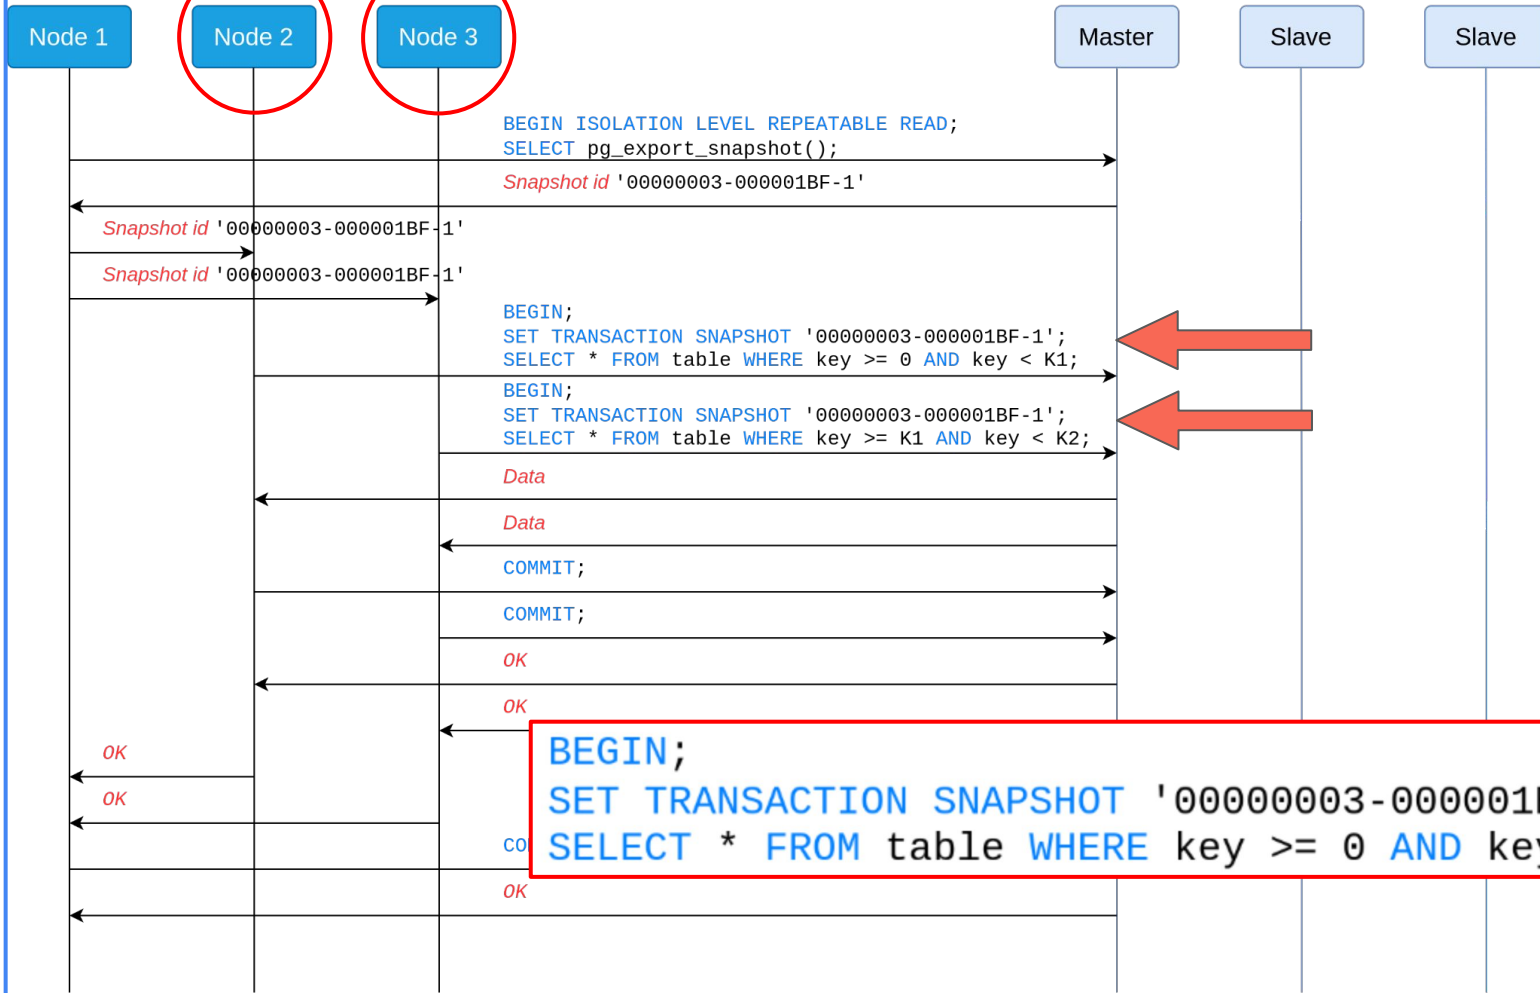
Snapshot id '00000003-000001BF-1'

Federated System

PostgreSQL



66



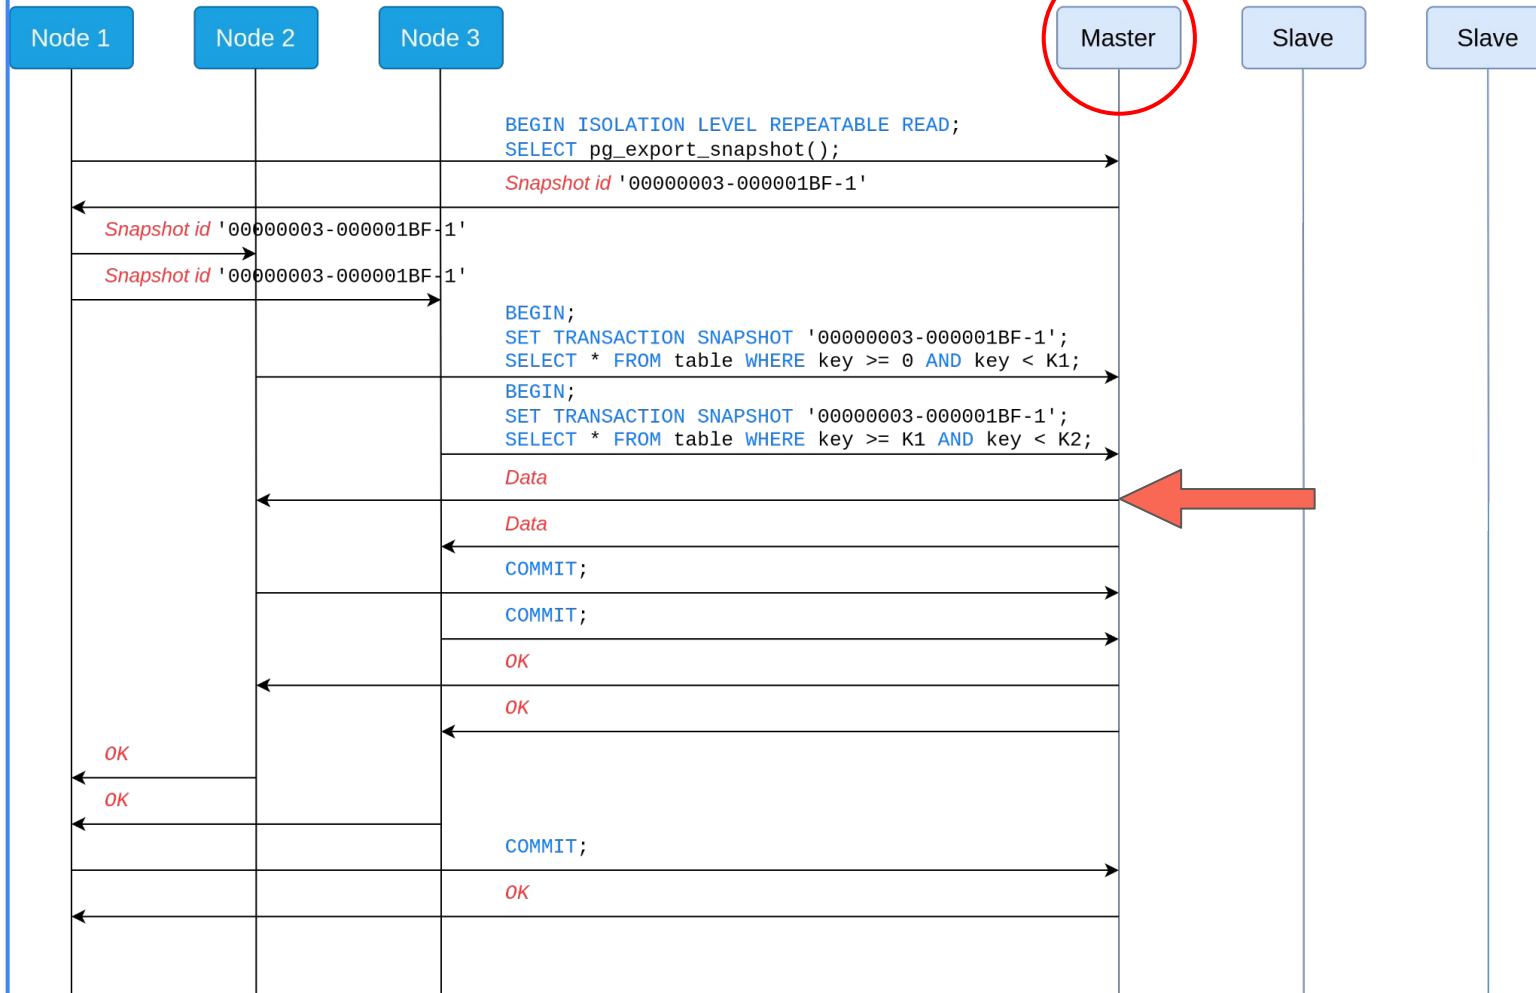
```
BEGIN;  
SET TRANSACTION SNAPSHOT '00000003-000001BF-1';  
SELECT * FROM table WHERE key >= 0 AND key < K1;
```

Federated System

PostgreSQL



67

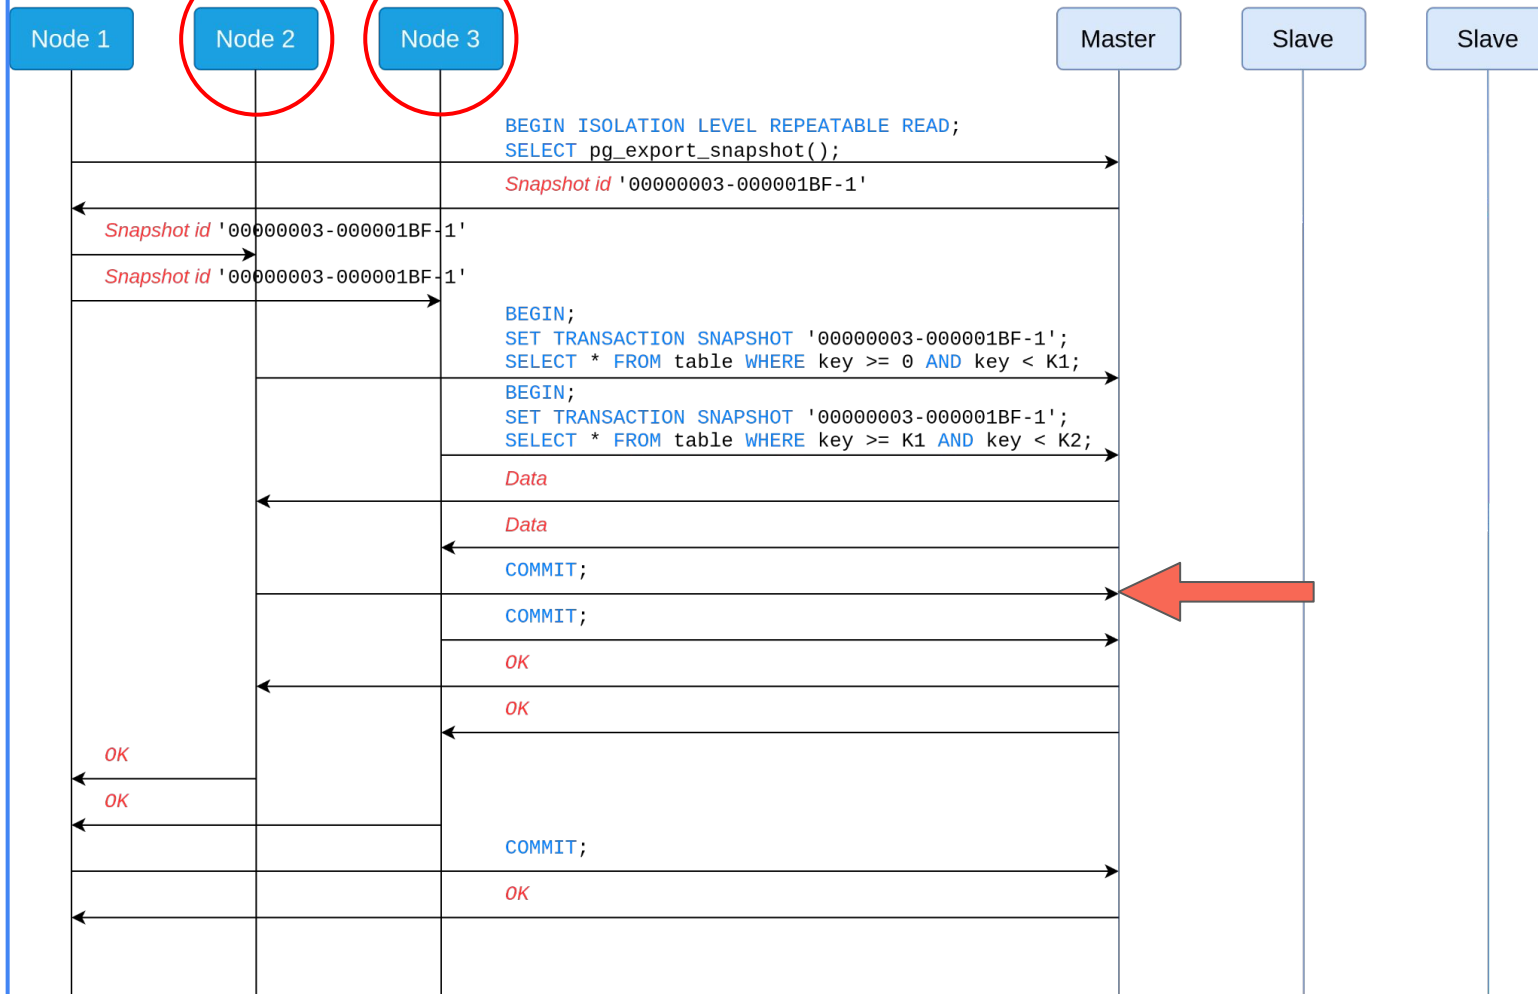


Federated System

PostgreSQL



68

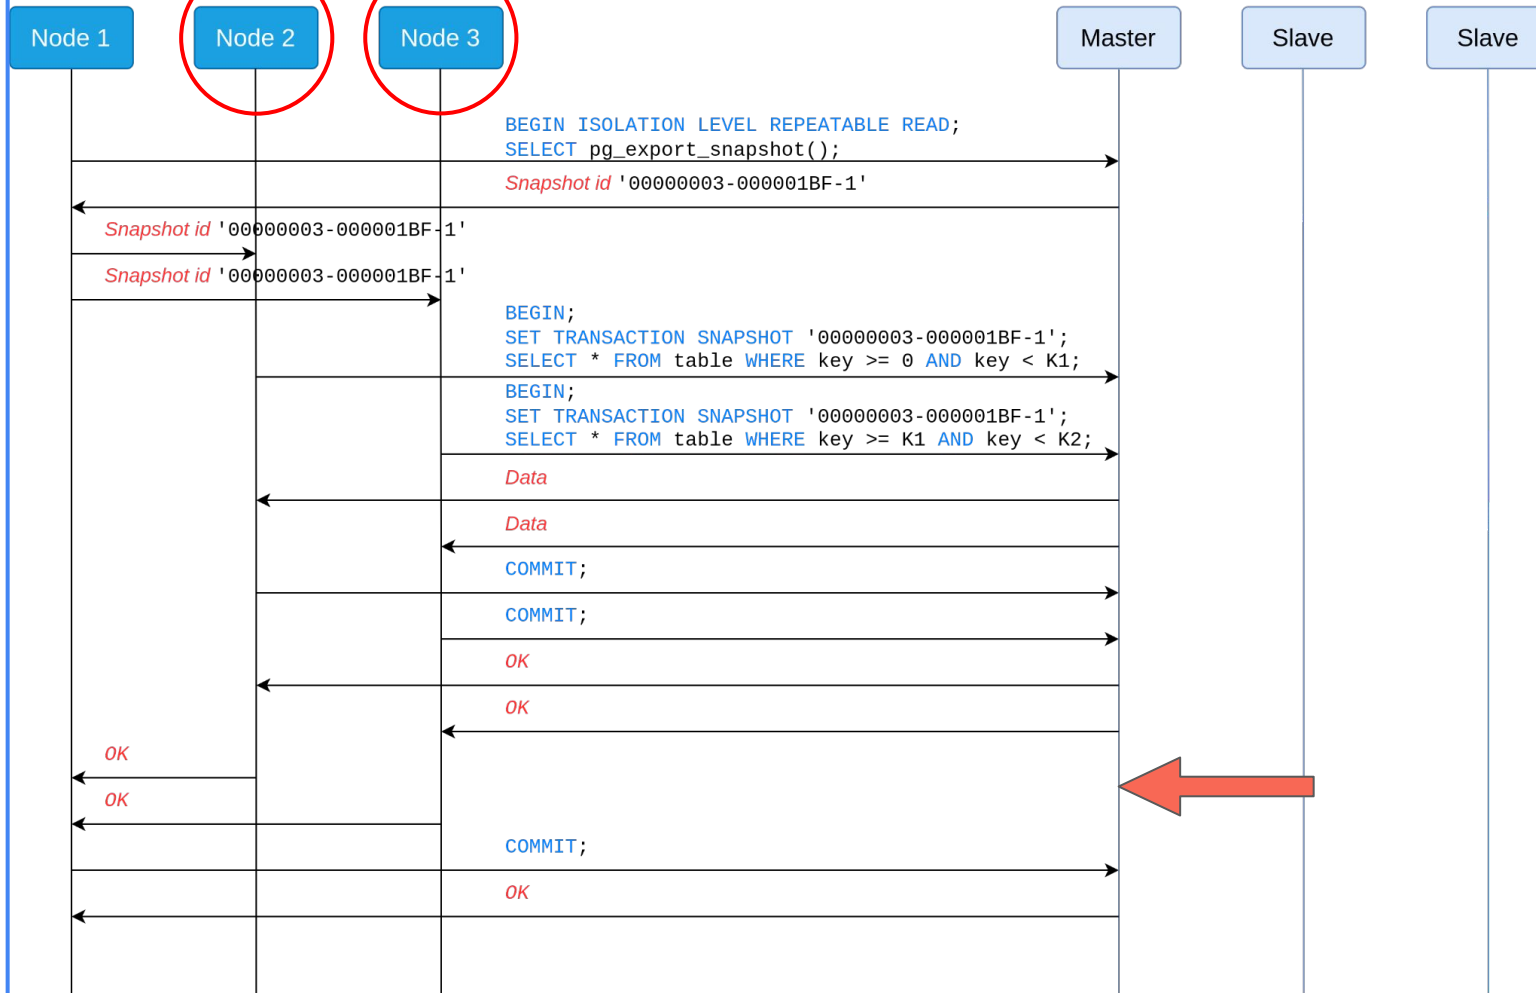


Federated System

PostgreSQL



69




Federated System

PostgreSQL



70

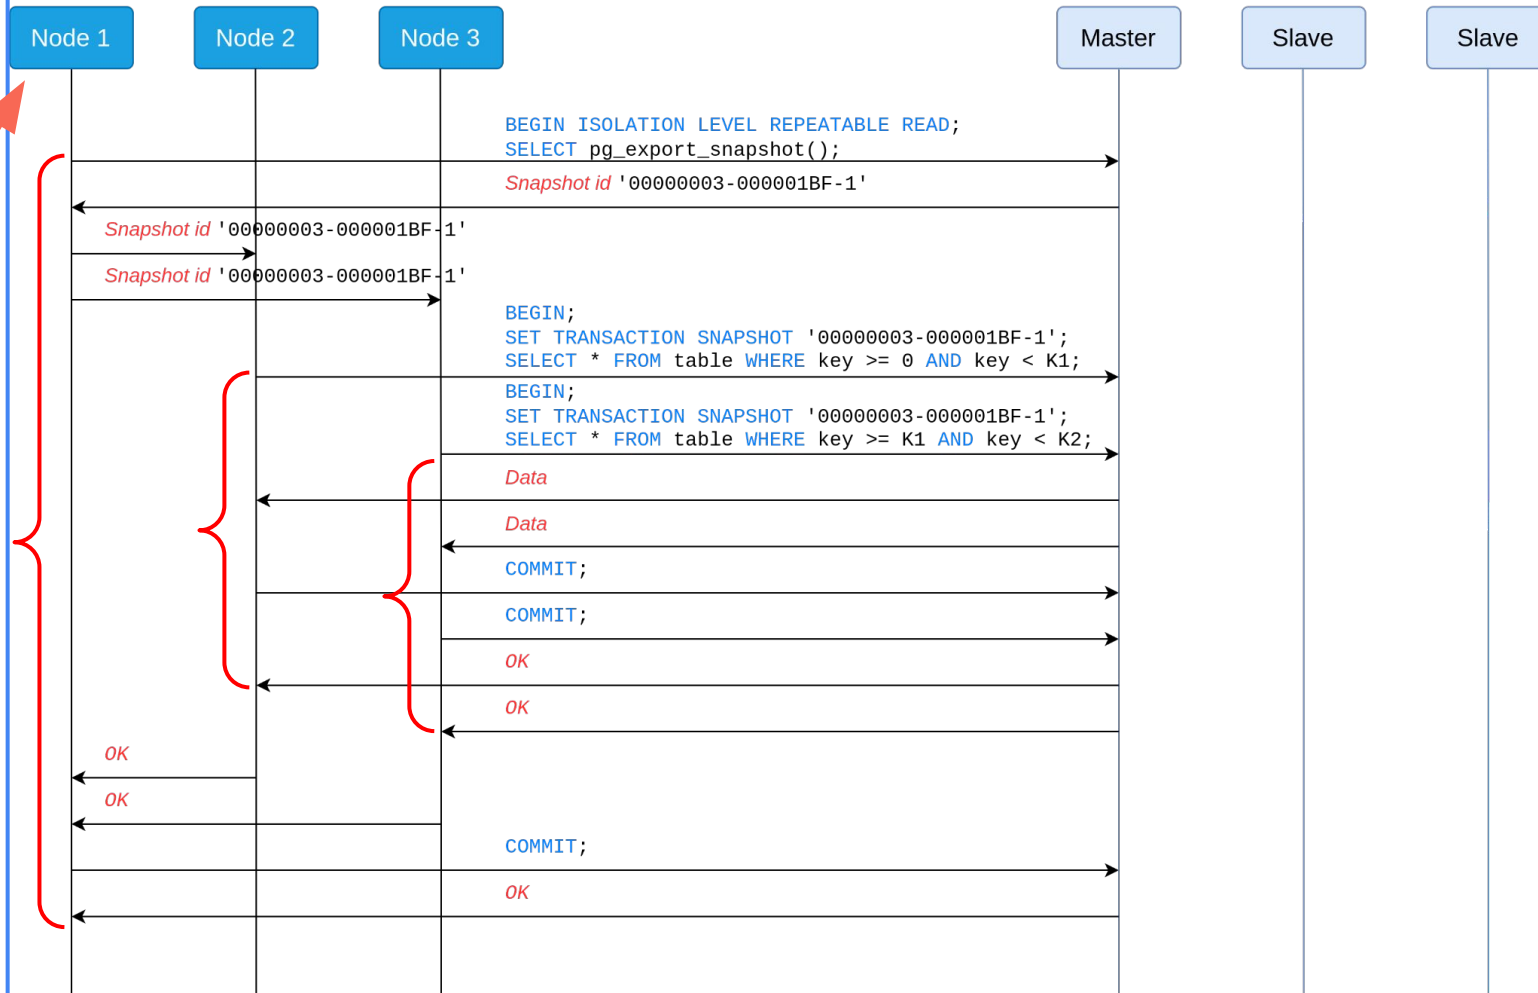


Federated System

PostgreSQL



71




Federated System

PostgreSQL



72



Консистентное чтение из PostgreSQL



73

Плюсы:

- снимоты экспортируемые

Минусы:


- снимоты только локальные
- сложная координация между узлами федеративной системы
- координатор держит долгую транзакцию

Federated System

MySQL



74




Federated System

MySQL



75




Federated System

MySQL



76




Federated System

MySQL



77




Federated System

MySQL



78




Federated System

MySQL



79




Federated System

MySQL



80




Federated System

MySQL



81




Federated System

MySQL



82



Консистентное чтение из MySQL

Плюсы:


- координатор не держит долгую транзакцию

Минусы:


- снимоты локальные и неэкспортируемые
- глобальная блокировка = **остановка записи во все БД**
- сложная координация между узлами федеративной системы

Federated System

MS SQL Server

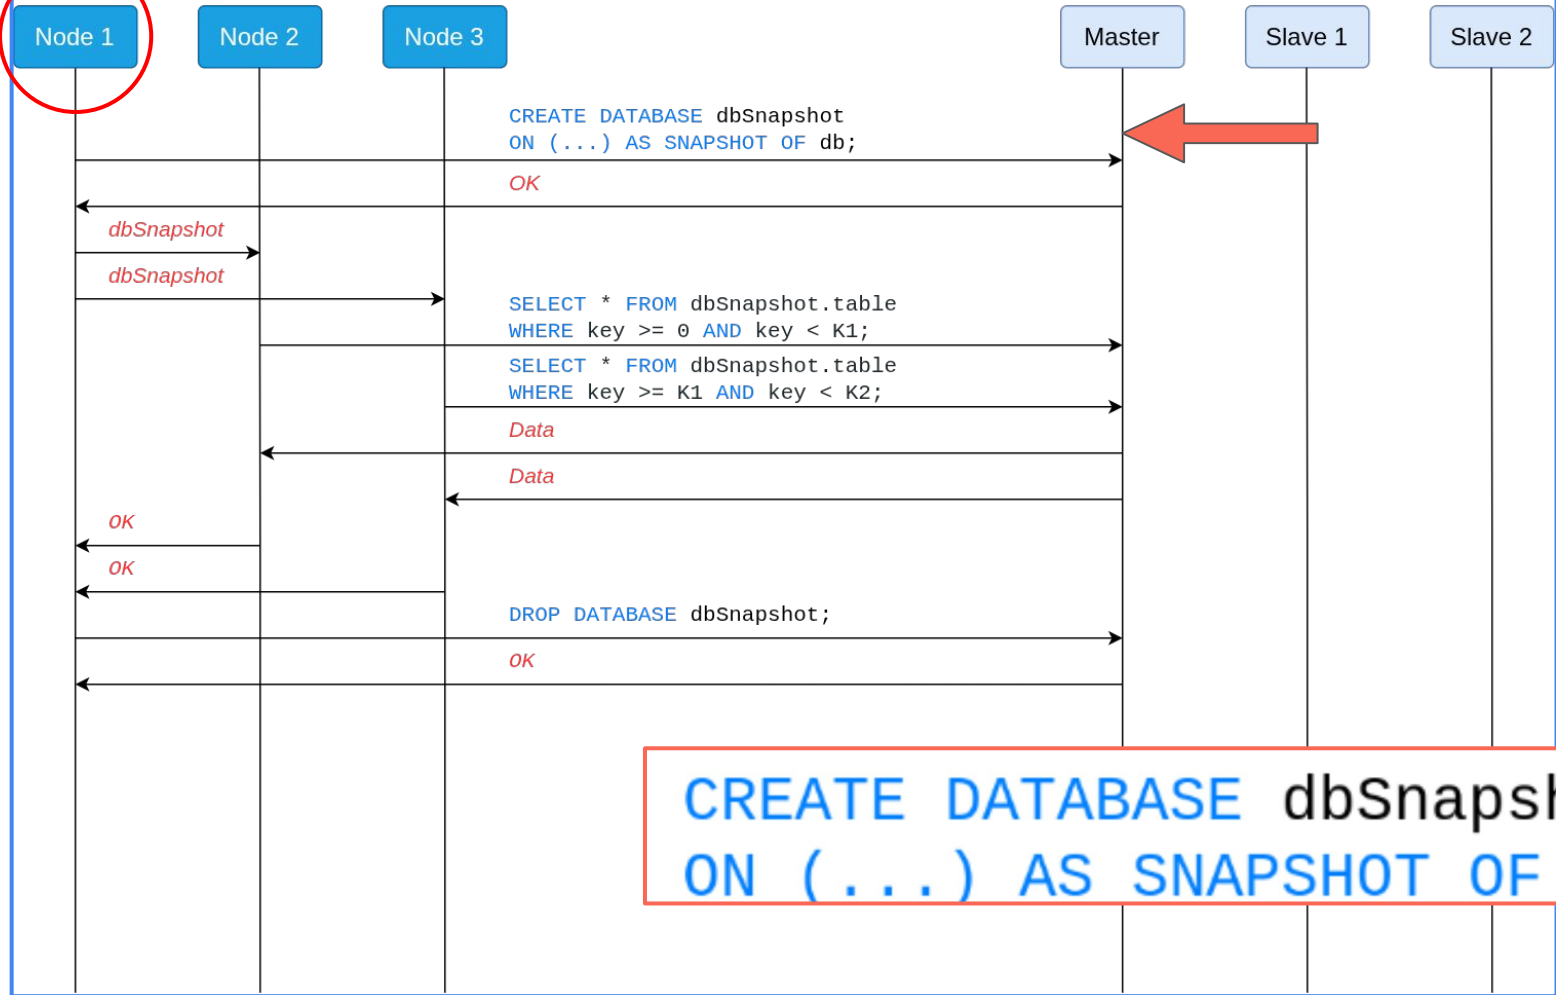




84



Federated System




MS SQL Server



CREATE DATABASE dbSnapshot
ON (...) AS SNAPSHOT OF db;


Federated System

MS SQL Server




Federated System

MS SQL Server




87



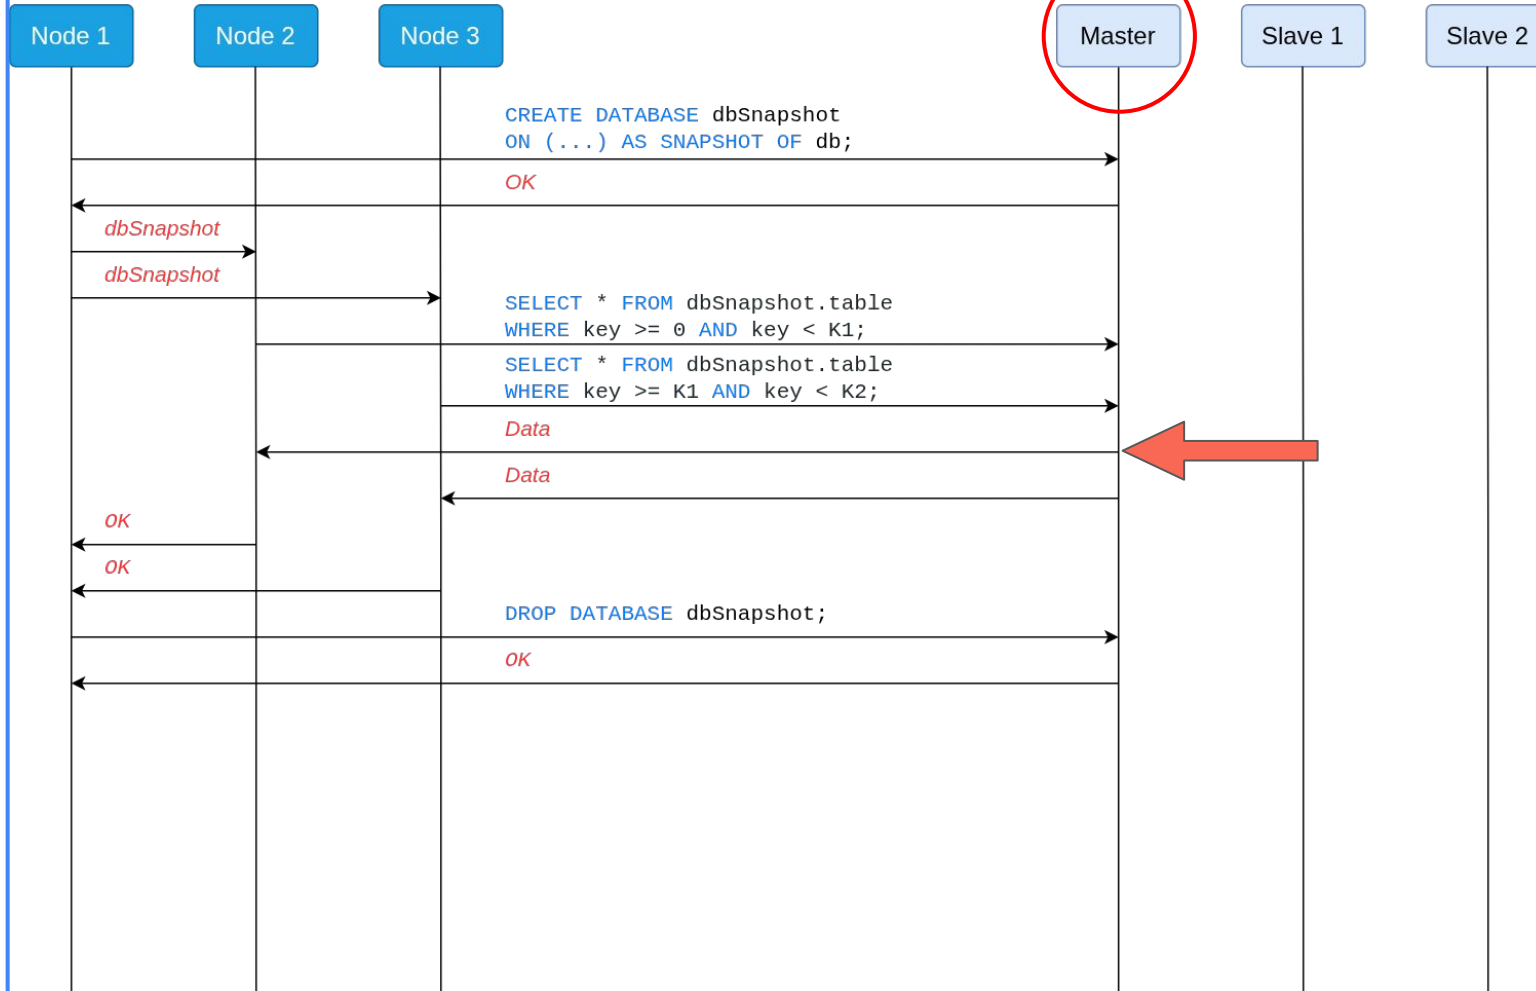
```
SELECT * FROM dbSnapshot.table
WHERE key >= 0 AND key < K1;
```

Federated System

MS SQL Server




88




Federated System

MS SQL Server





89




Federated System

MS SQL Server



Консистентное чтение из MS SQL Server



91

Плюсы:

- снимоты экспортируемые
- координатор не держит долгую транзакцию

Минусы:


- снимоты локальные
- copy-on-write: при интенсивных записях в таблицу большие накладные расходы
- сложная координация между узлами федеративной системы

Federated System

Oracle

ORACLE

92




Federated System

Oracle

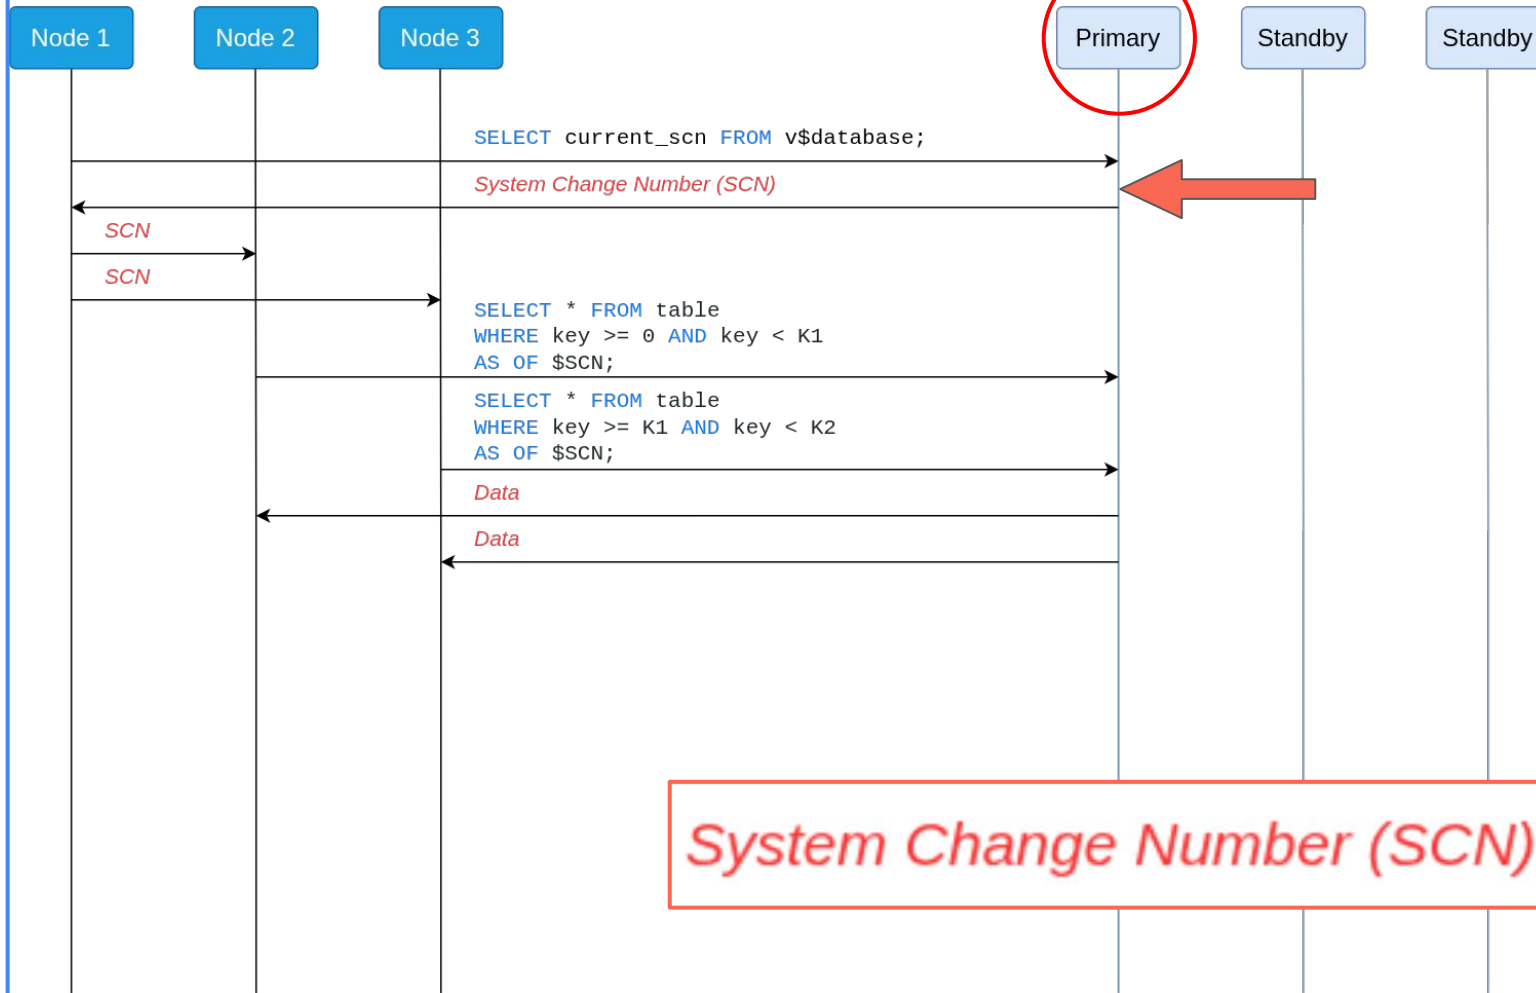
ORACLE

93



Federated System

Oracle



ORACLE


94

Federated System

Oracle

ORACLE

95




Federated System

Oracle

ORACLE


96



```
SELECT * FROM table
WHERE key >= 0 AND key < K1
AS OF $SCN;
```


Federated System

Oracle



ORACLE

97

Плюсы:

- снимки экспортируемые
- снимки могут быть глобальными (Active Data Guard)
- координатор не держит долгую транзакцию
- нет явной фазы очистки

Минусы:

- требуются ресурсы для Flashback Queries (UNDO tablespace)
- ошибка ORA-01555: snapshot too old


Многопоточное консистентное чтение из Distributed SQL

Federated System

CockroachDB



100

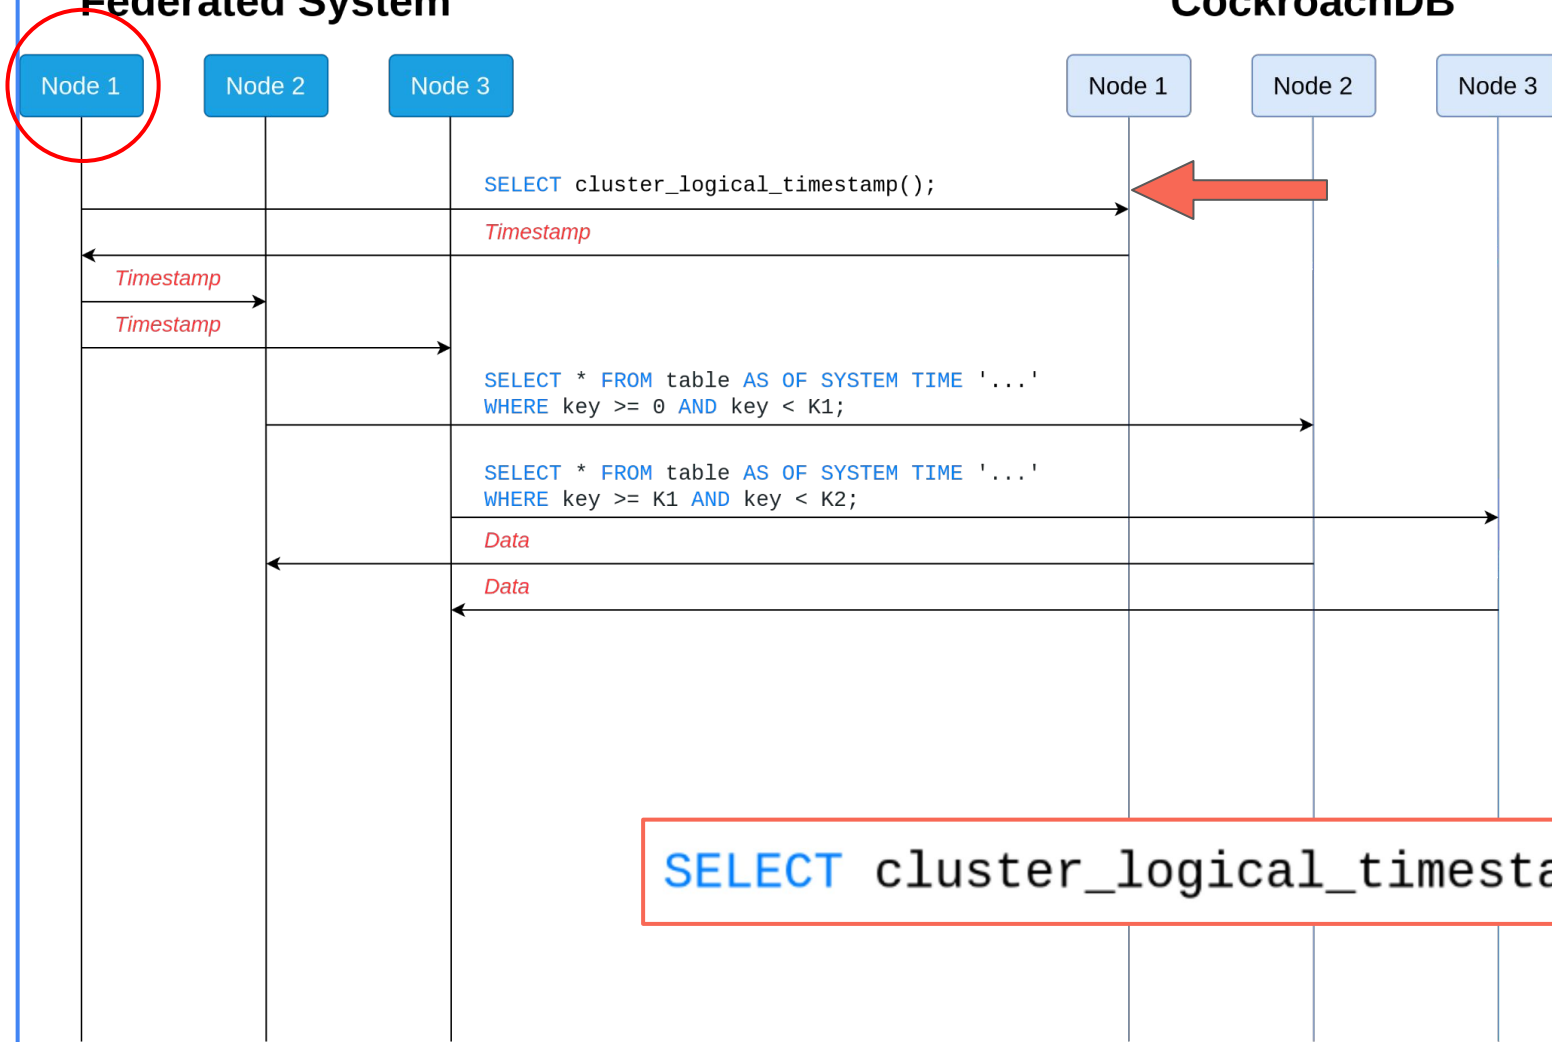


Federated System

CockroachDB



101

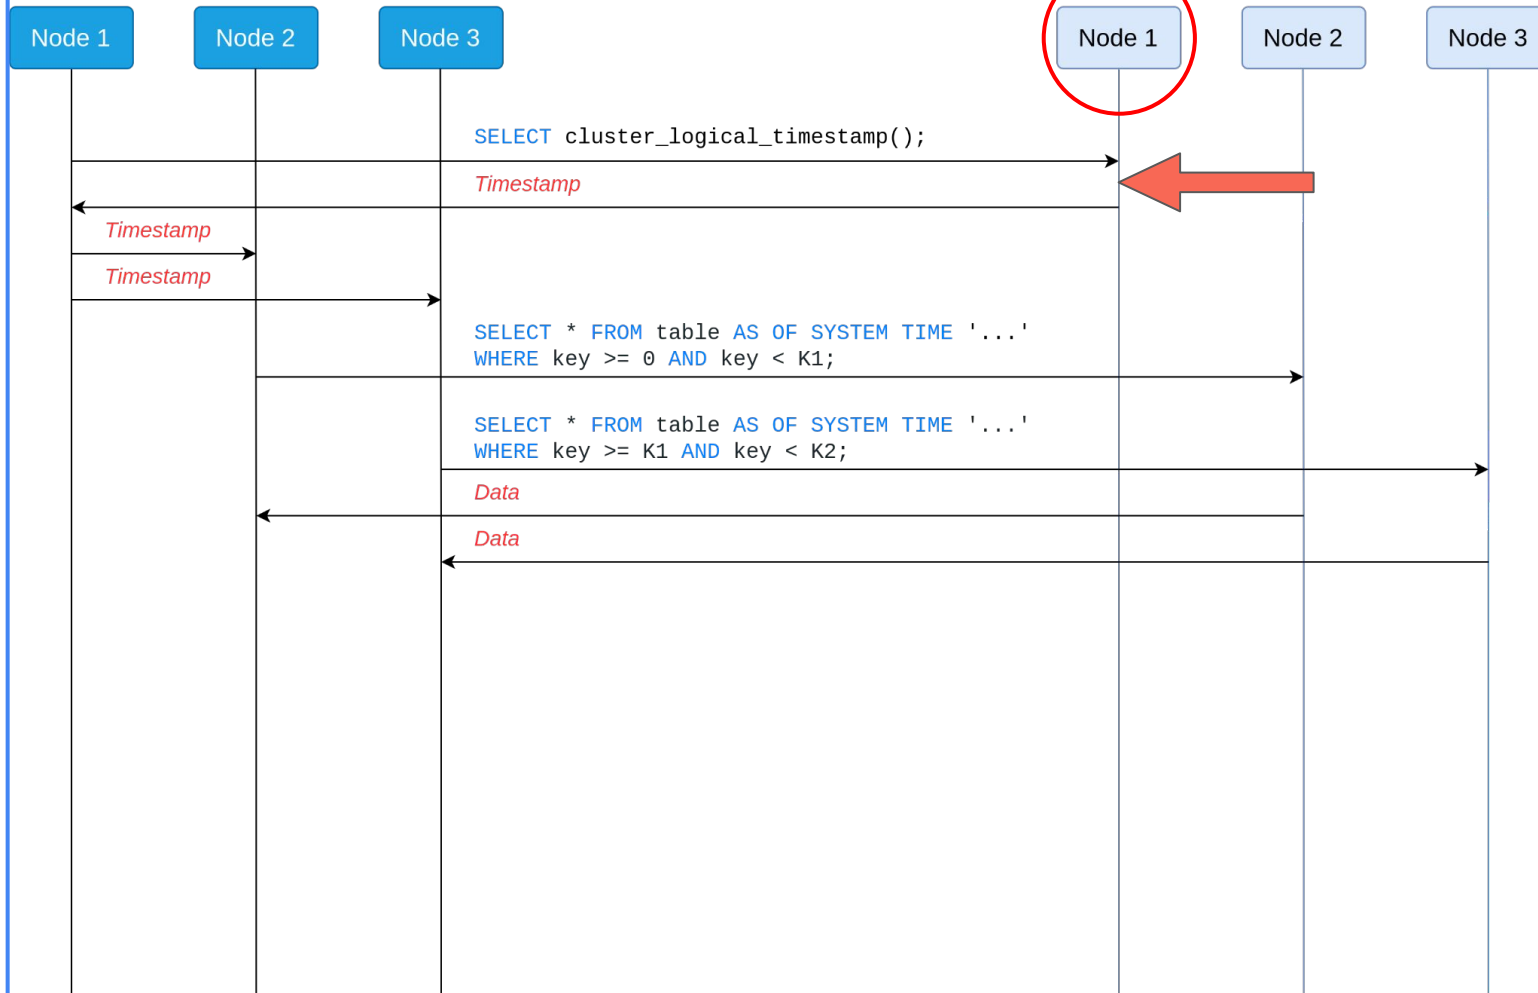


Federated System

CockroachDB

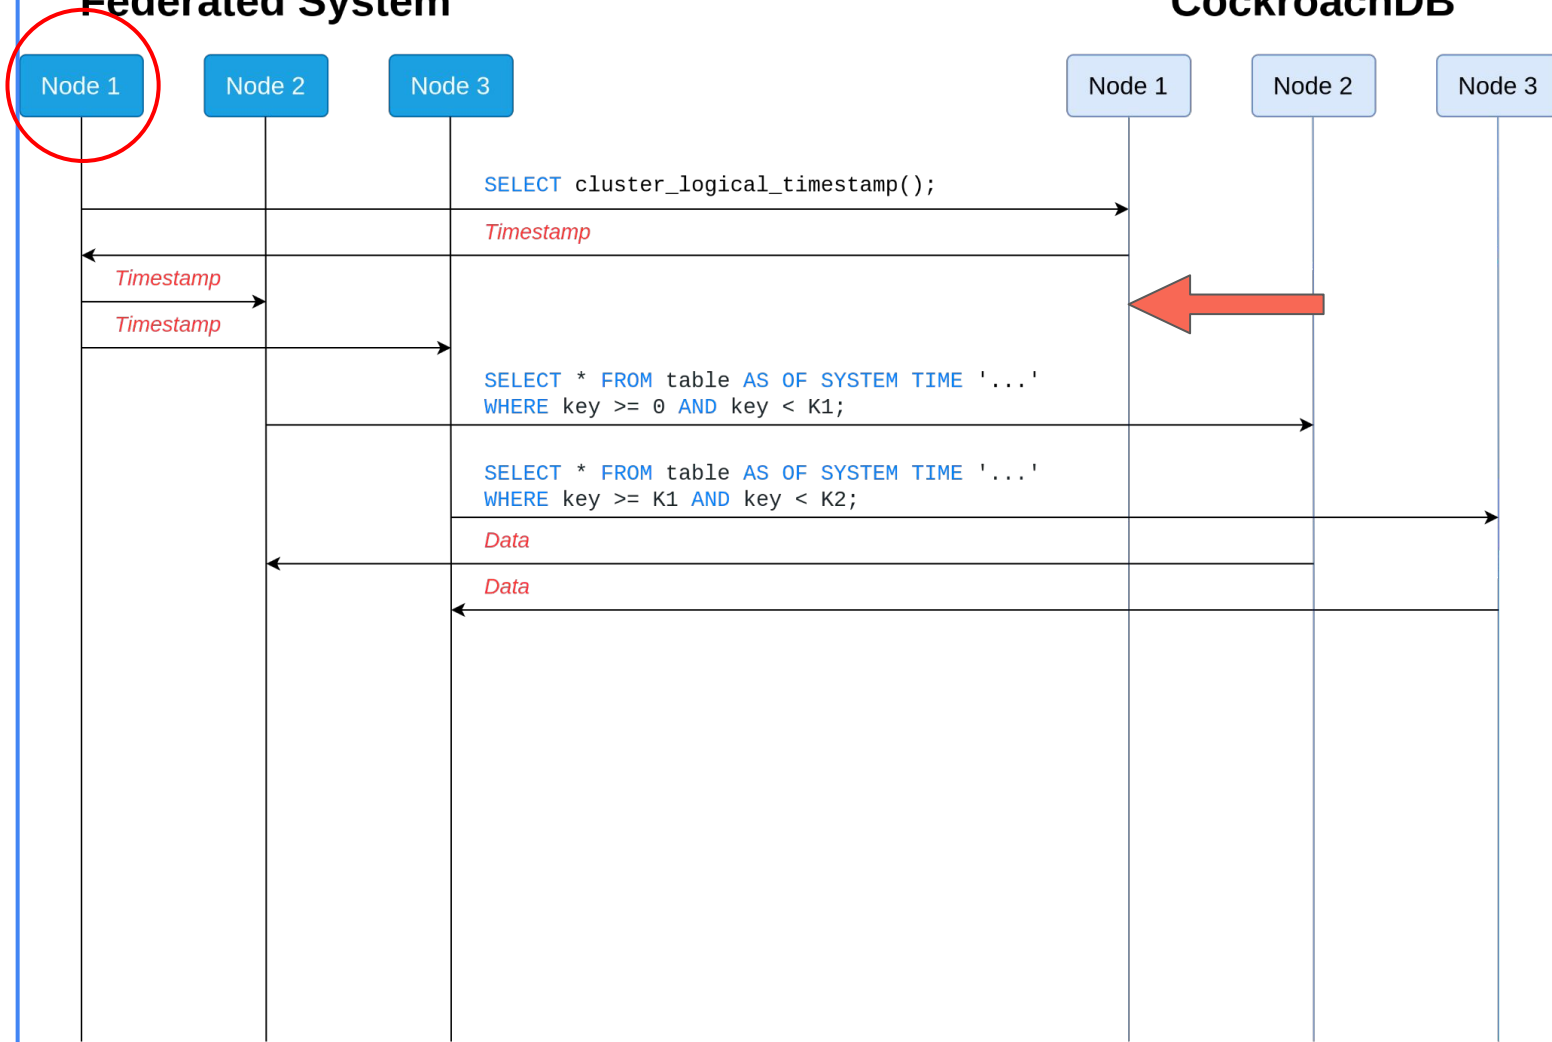


102



Federated System

CockroachDB

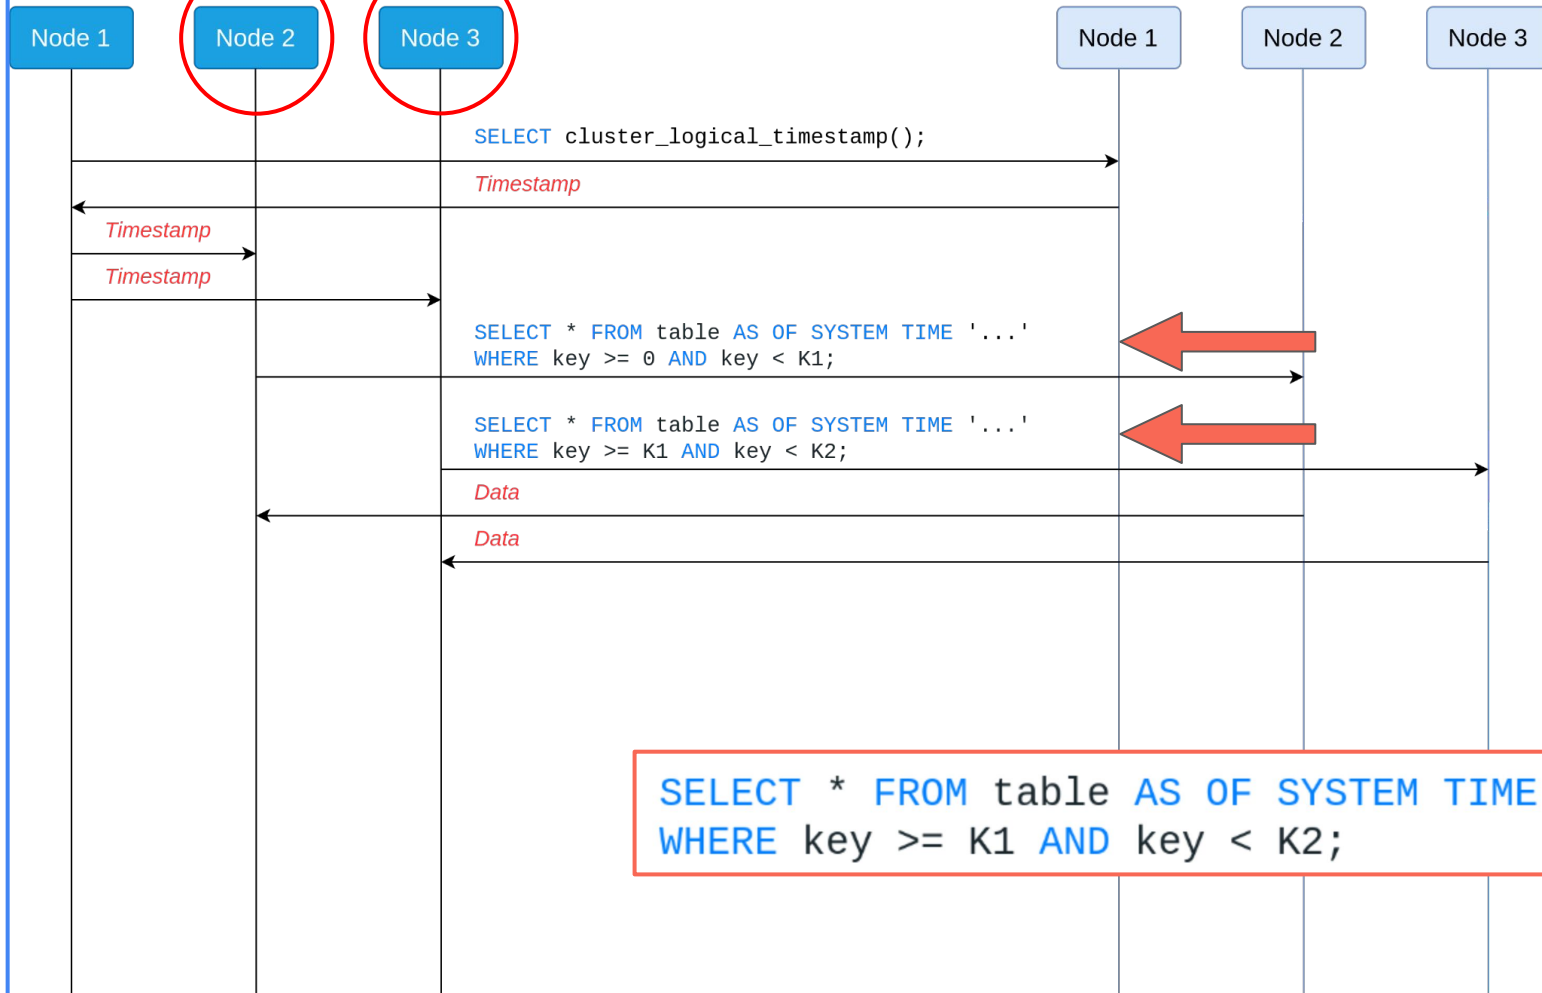


Federated System

CockroachDB



104




Federated System

CockroachDB



105



Консистентное чтение из CockroachDB



106

Плюсы:

- снимоты экспортируемые и глобальные - **гарантия горизонтальной масштабируемости**
- координатор не держит долгую транзакцию
- нет явной фазы очистки

Минусы:

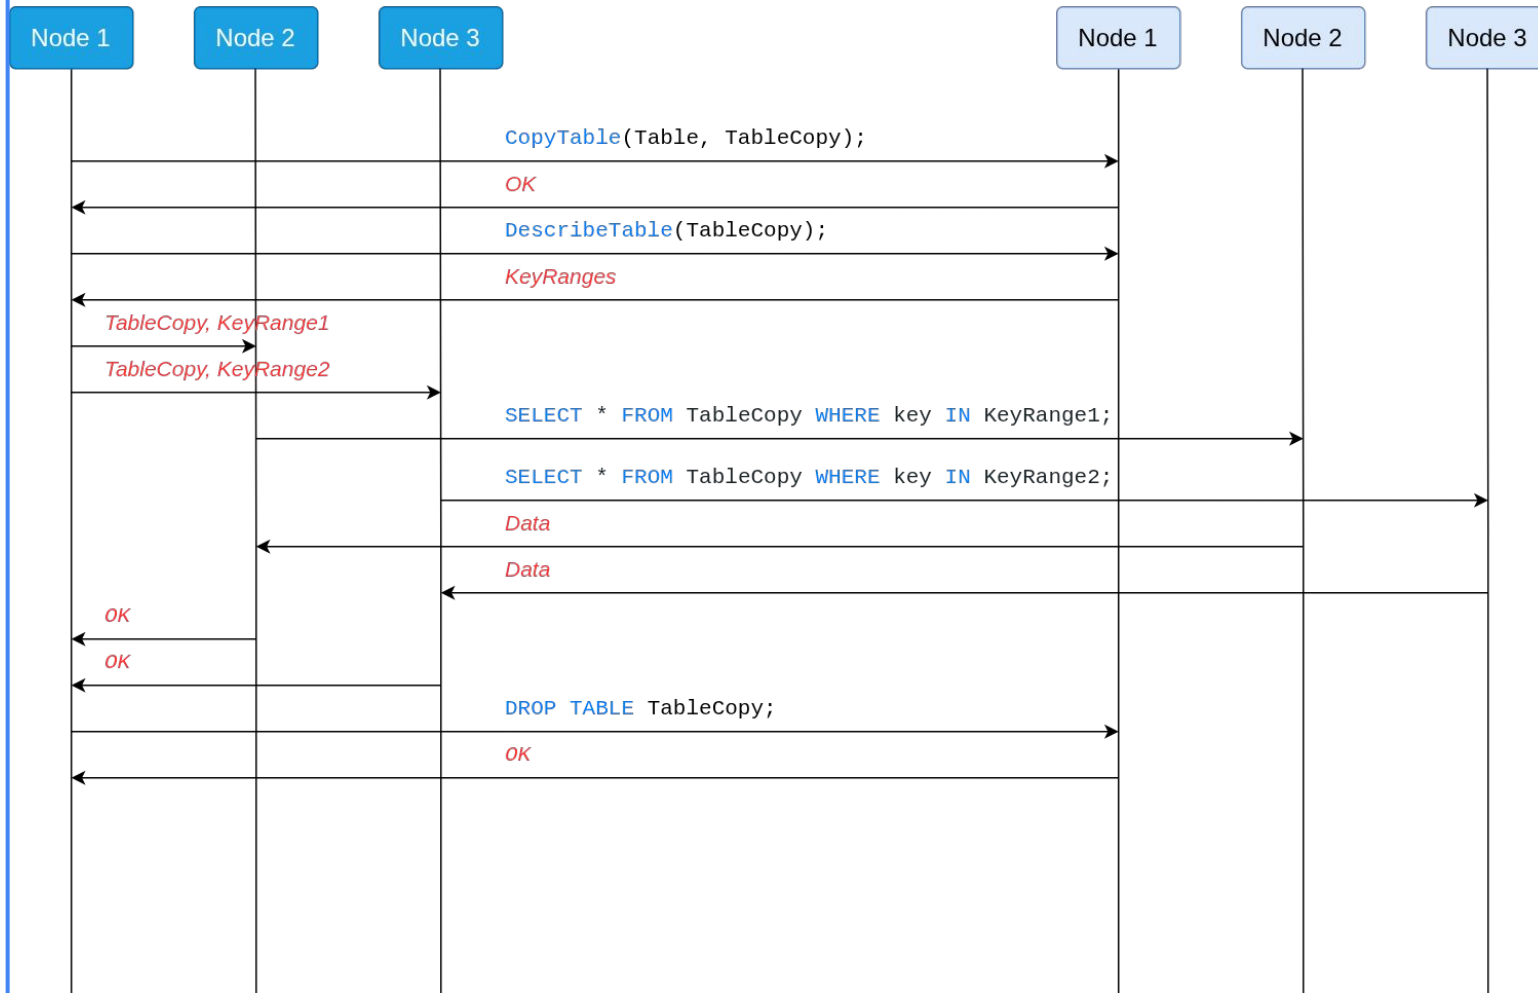
- в исключительных случаях ошибка `MVCC_HISTORY_MUTATED`

Federated System

YDB (row table)



107




Federated System

YDB (row table)



108



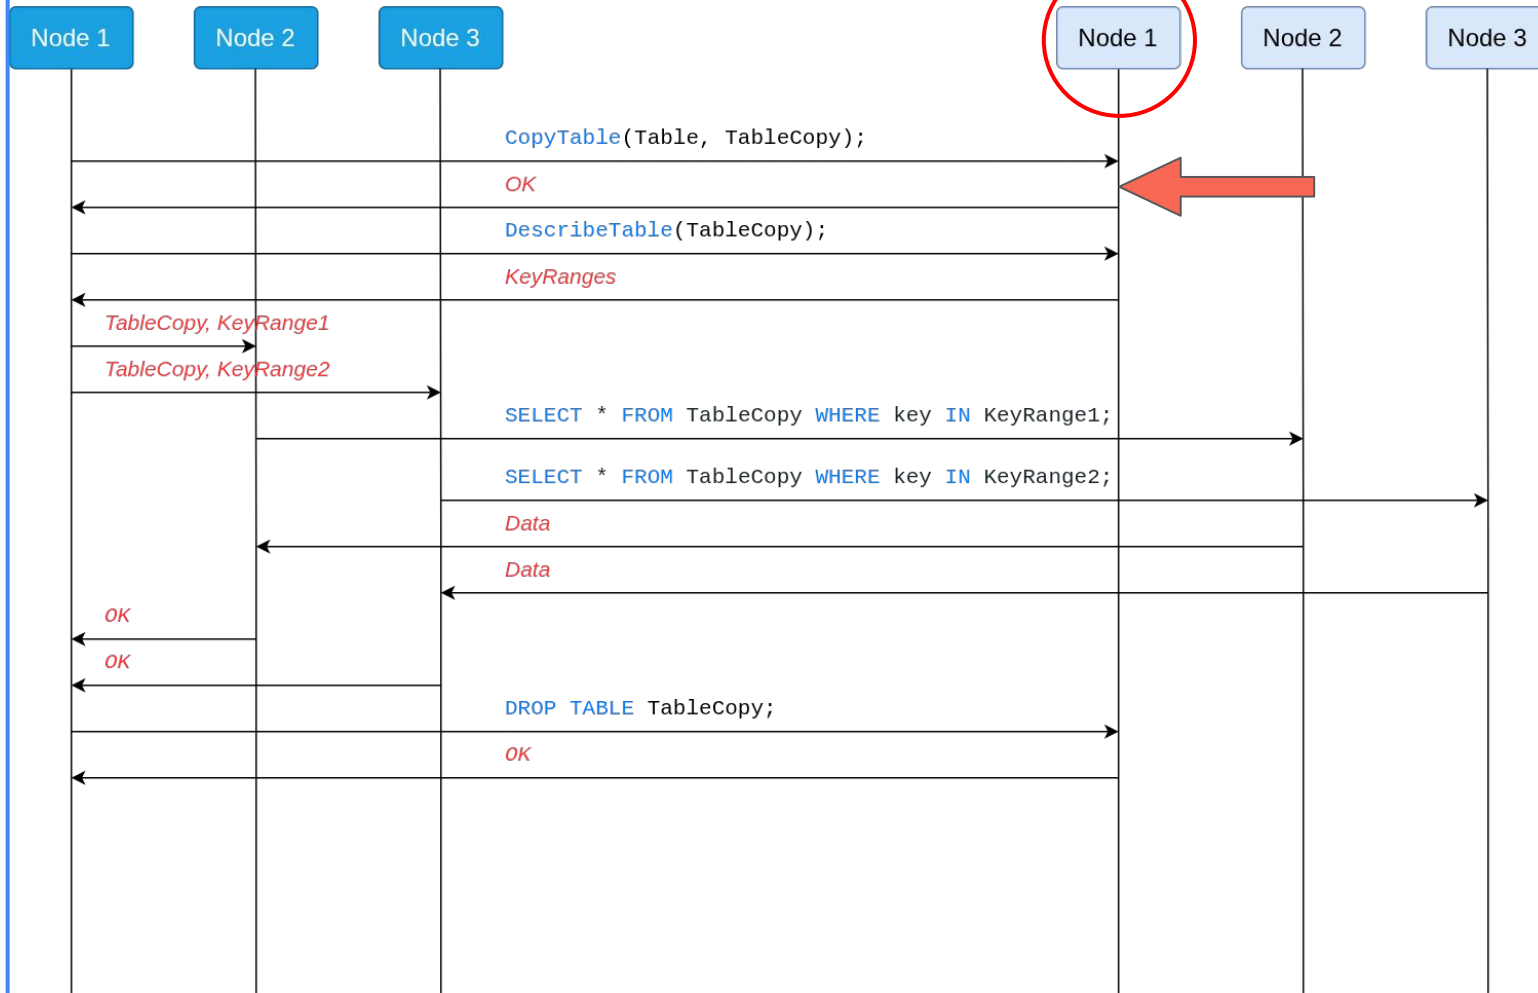
`CopyTable(Table, TableCopy);`

Federated System

YDB (row table)



109

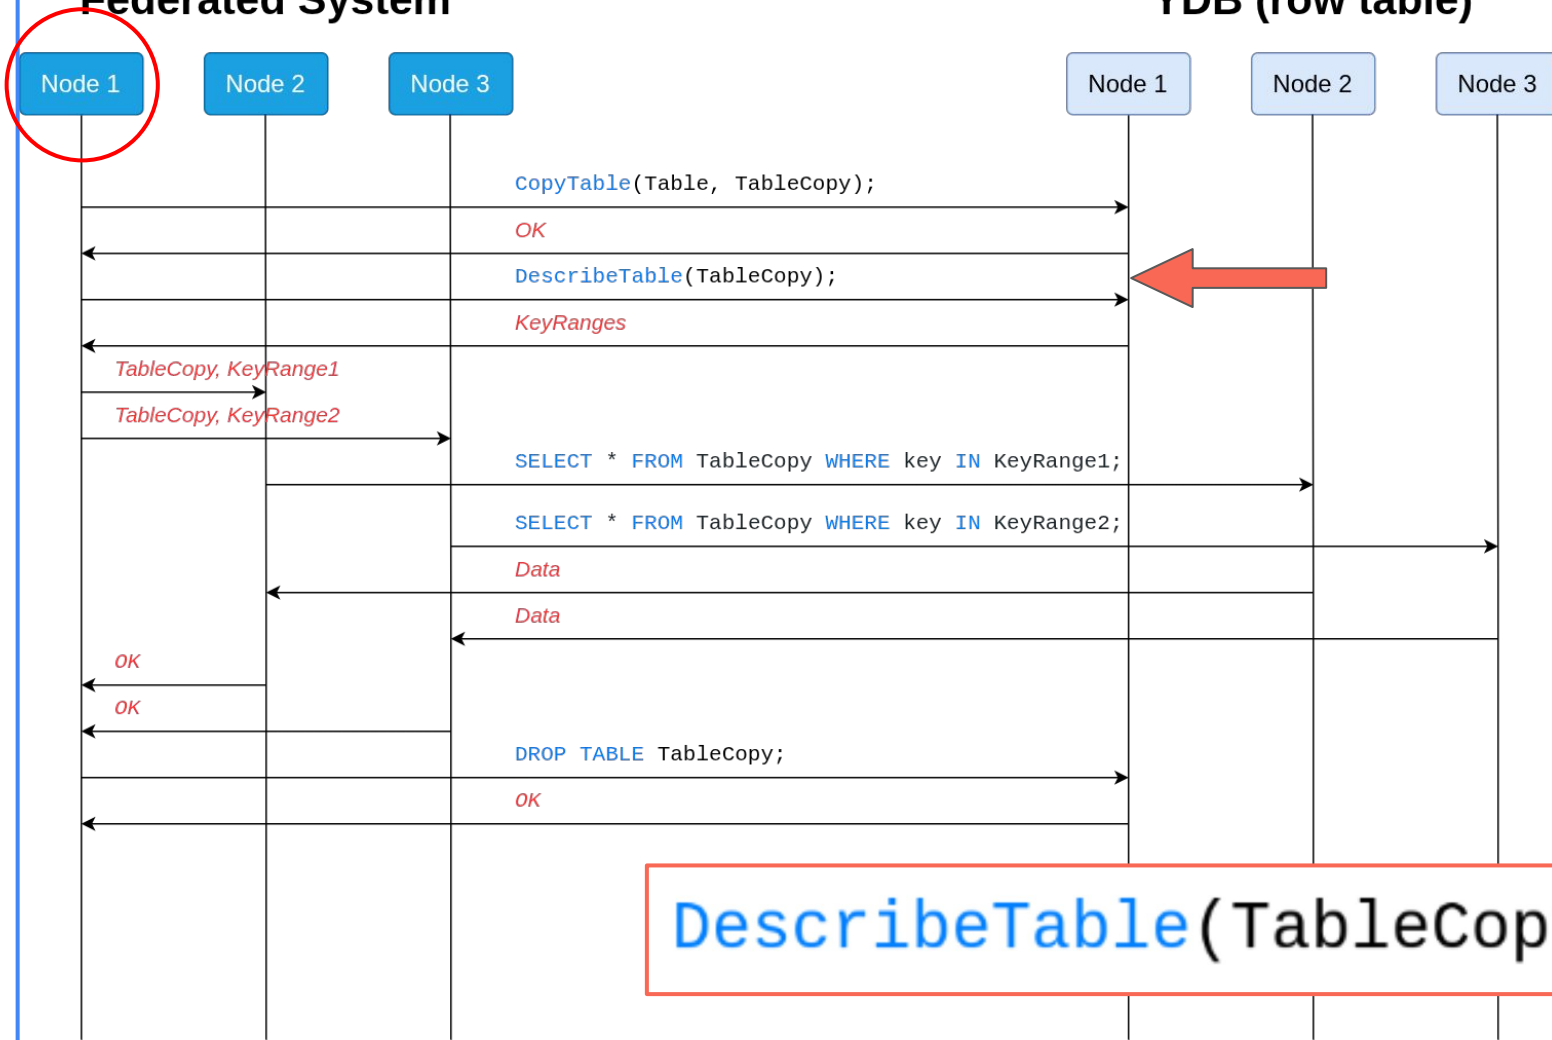


Federated System

YDB (row table)



110



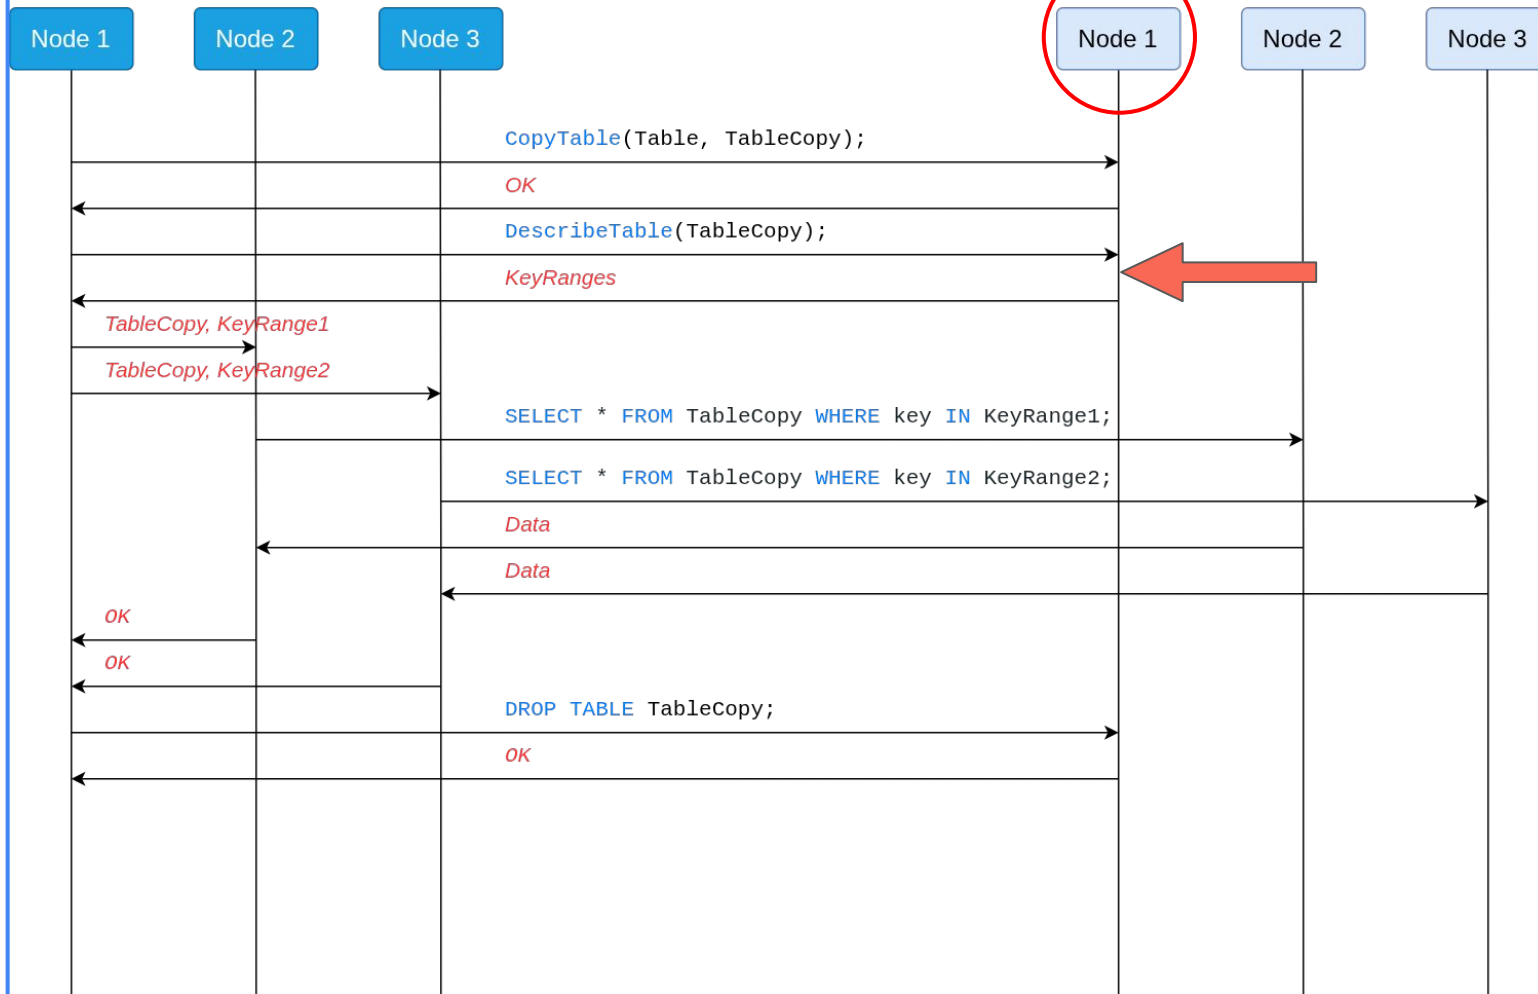
`DescribeTable(TableCopy);`

Federated System

YDB (row table)



111

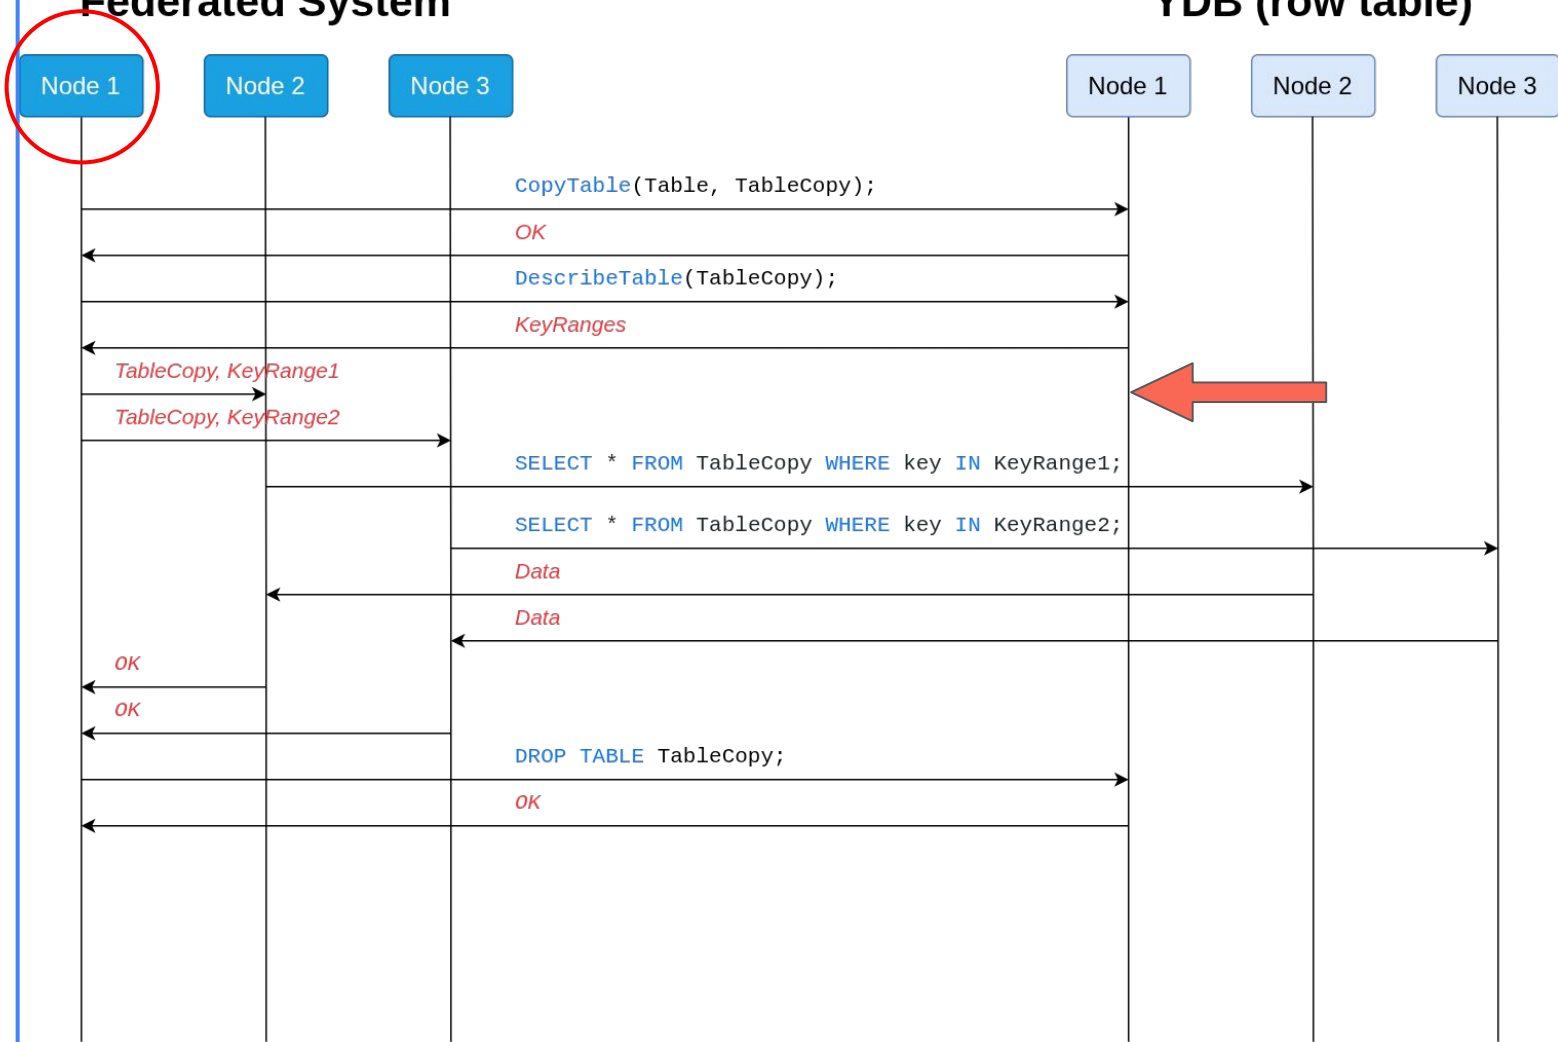


Federated System

YDB (row table)



112

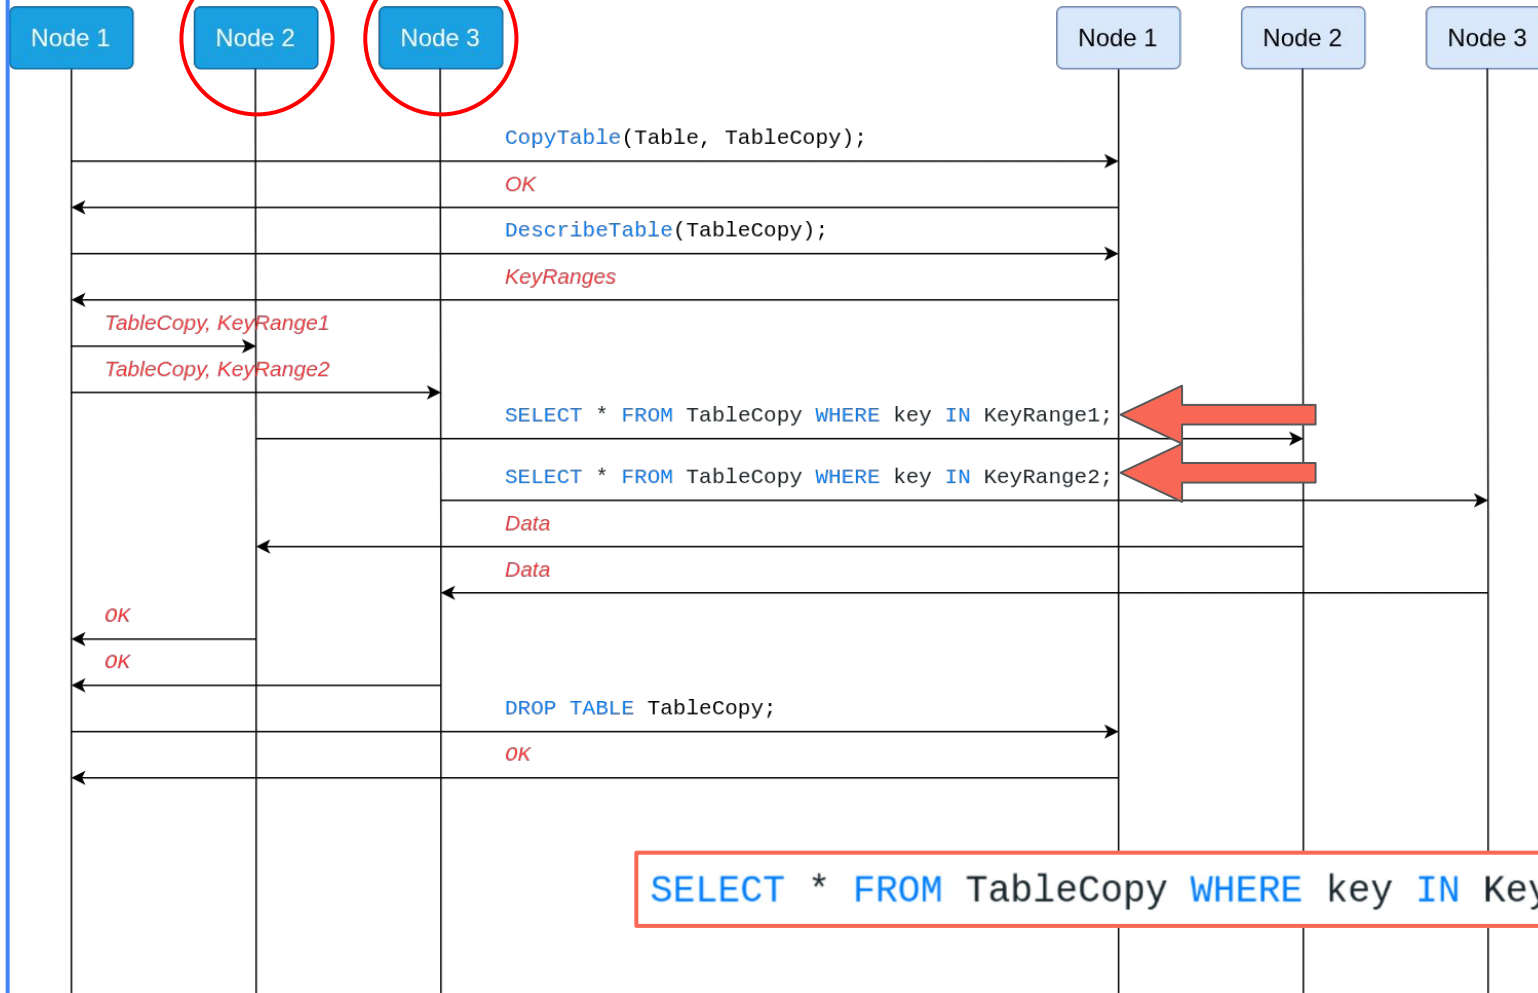


Federated System

YDB (row table)



113

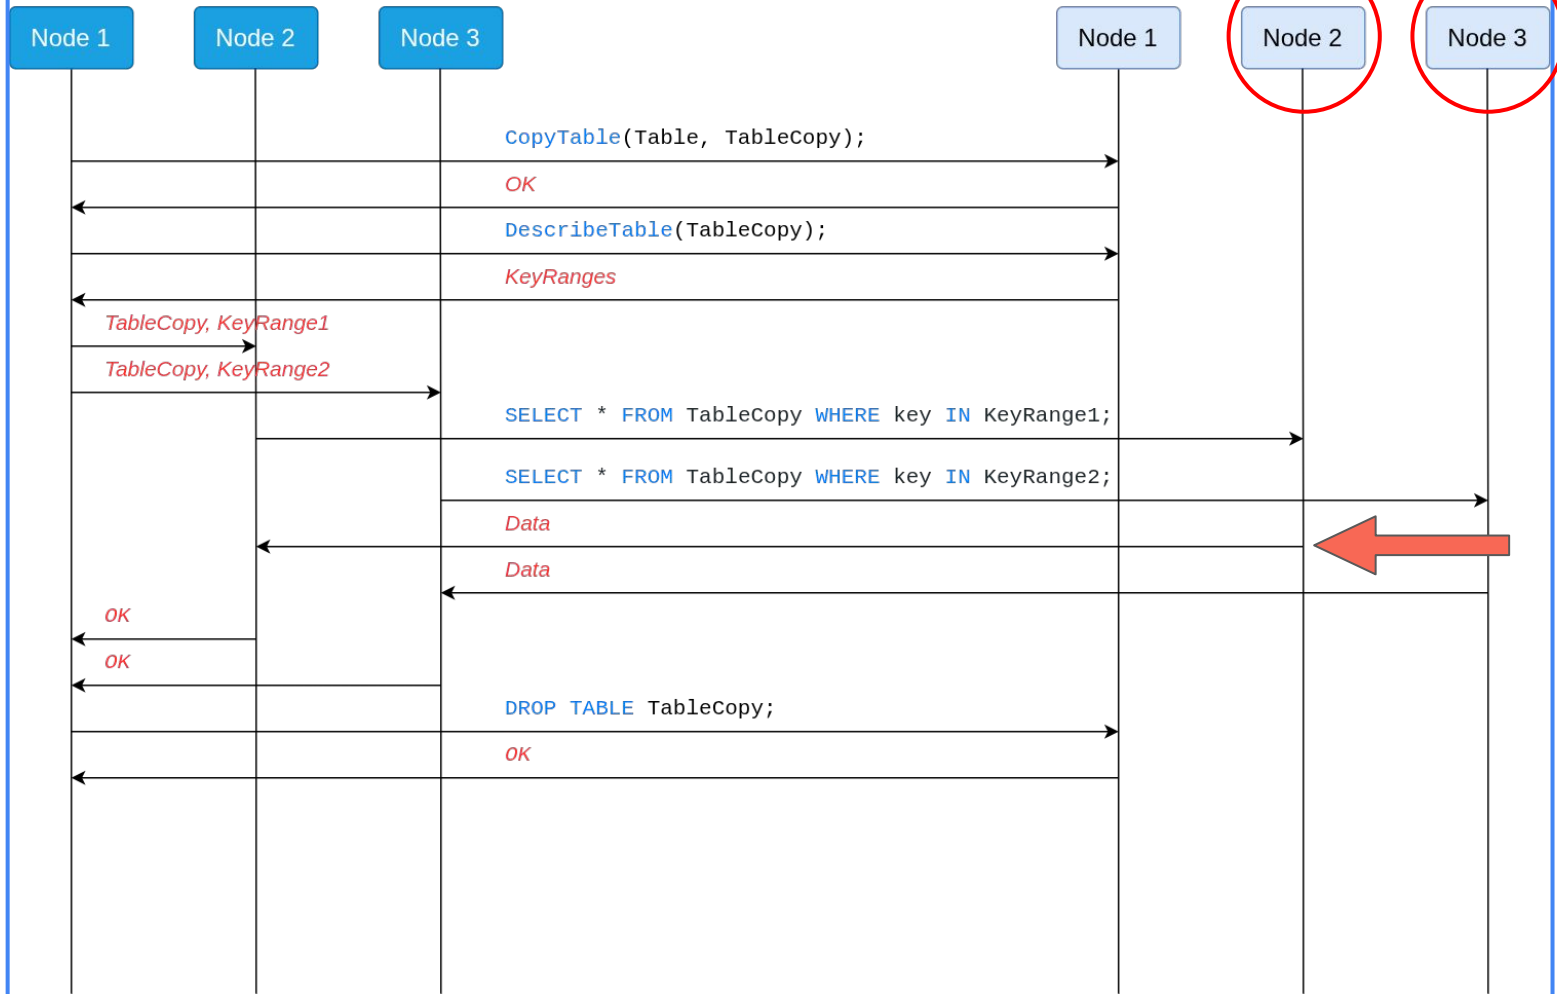


Federated System

YDB (row table)



114




Federated System

YDB (row table)



115




Federated System

YDB (row table)



116



Консистентное чтение из YDB (row tables)



117

Плюсы:

- снимоты экспортируемые и глобальные - **гарантия горизонтальной масштабируемости**
- снимот не может устареть
- координатор не держит долгую транзакцию

Минусы:

- явная фаза очистки ресурсов

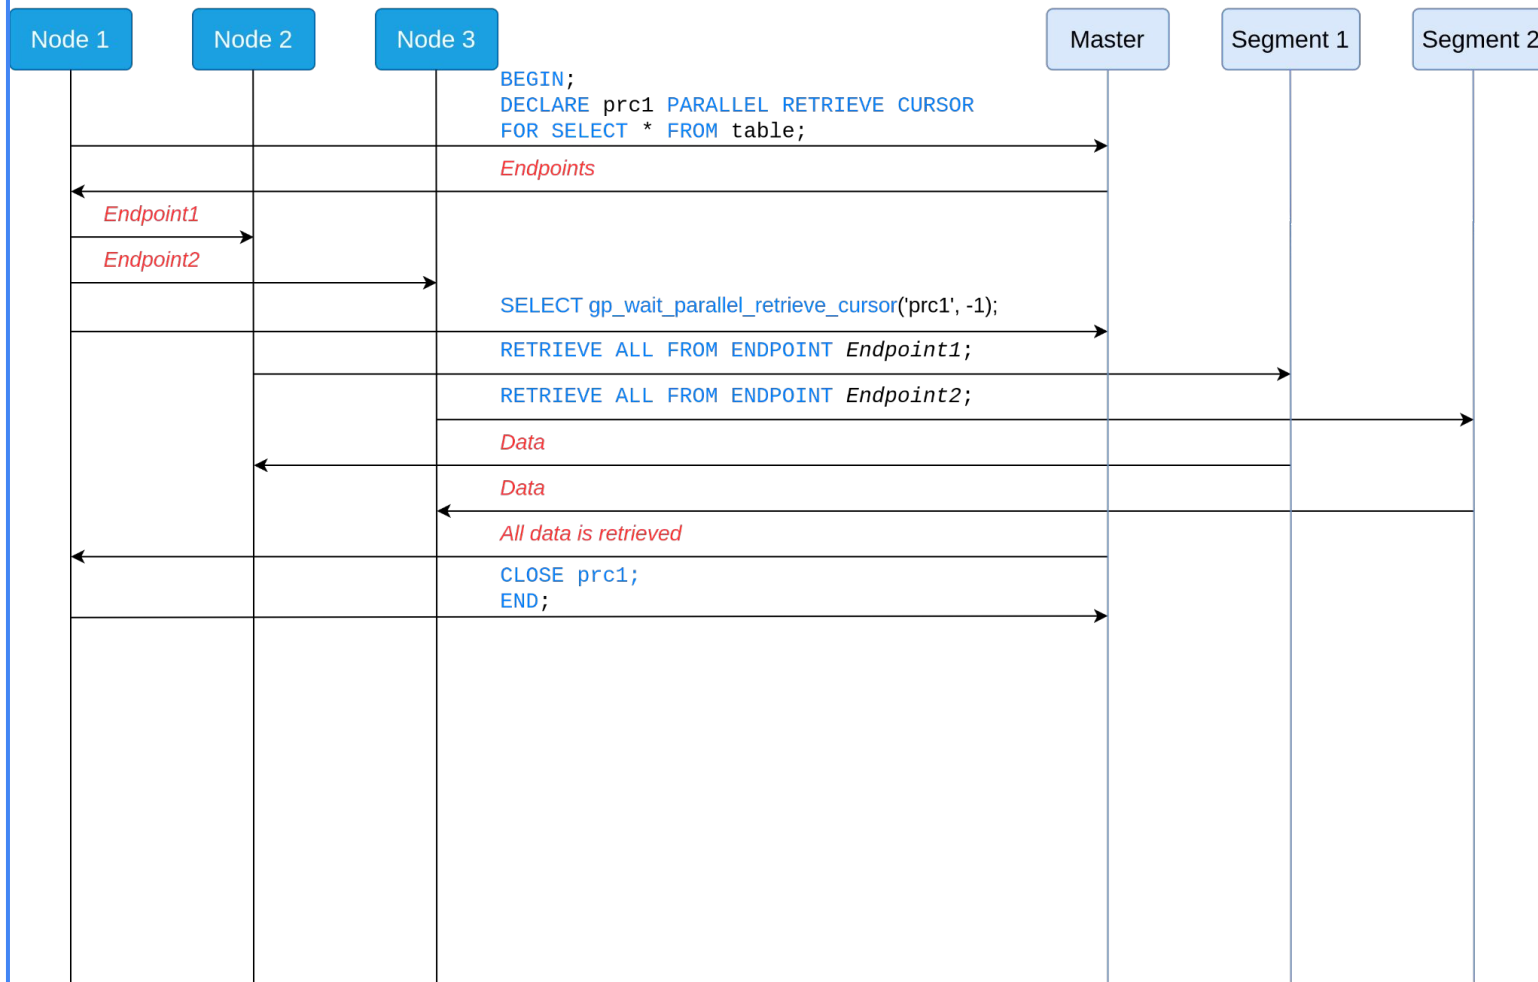
Многопоточное консистентное чтение из аналитических СУБД

Federated System

Greenplum

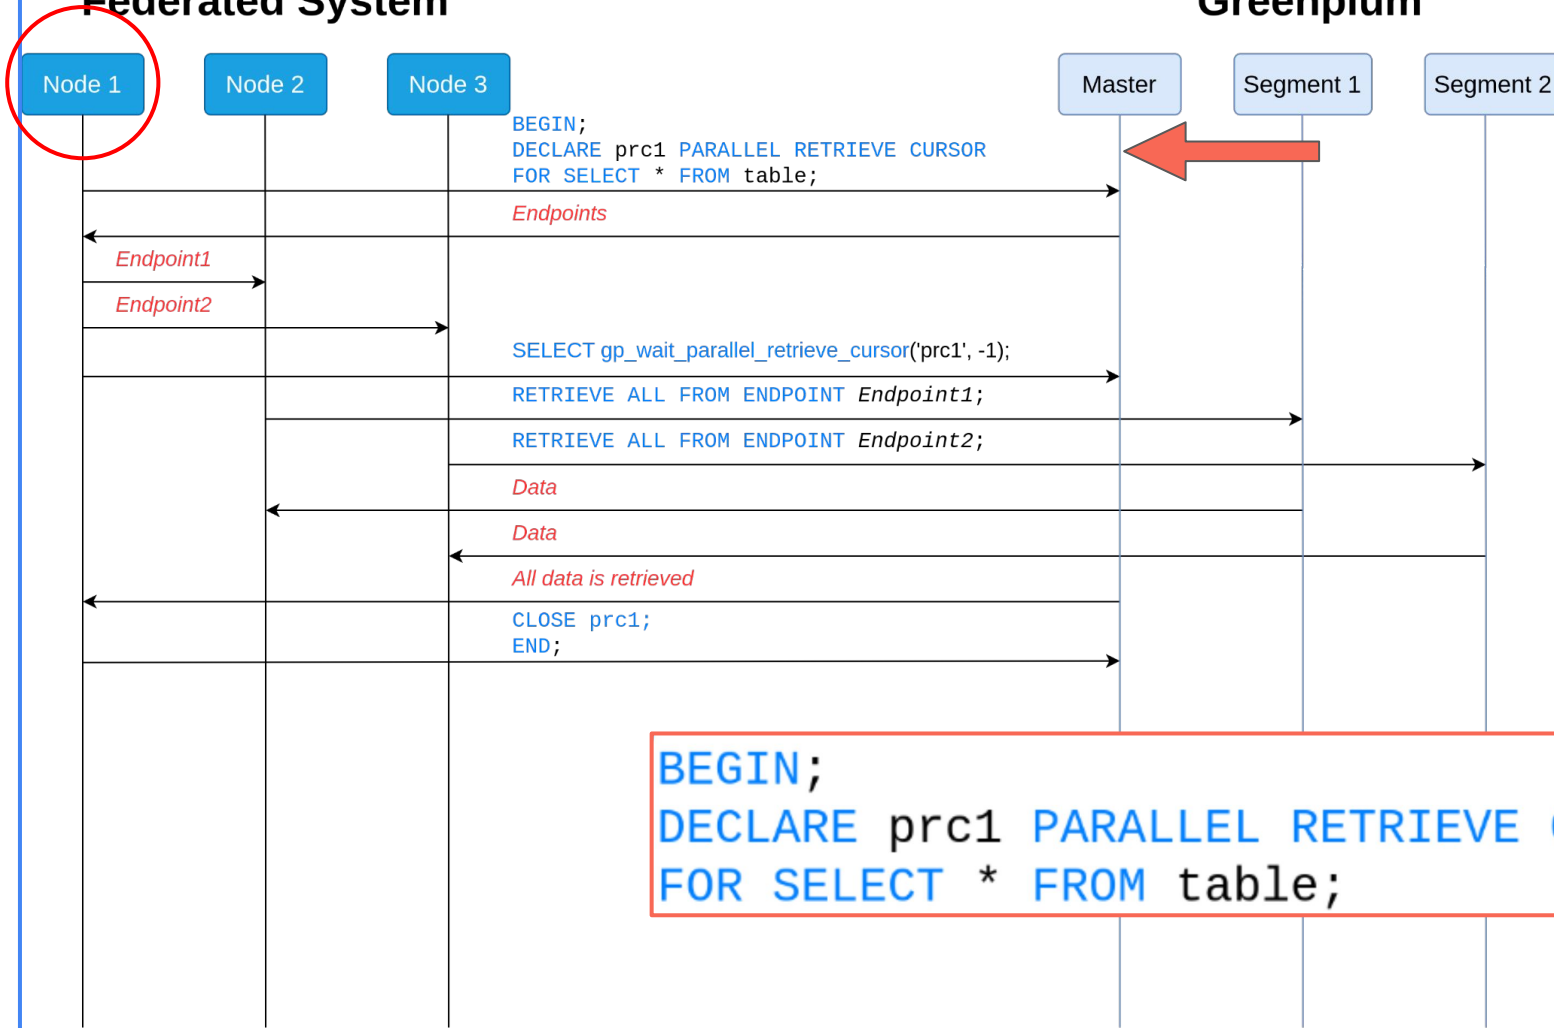


119



Federated System

Greenplum

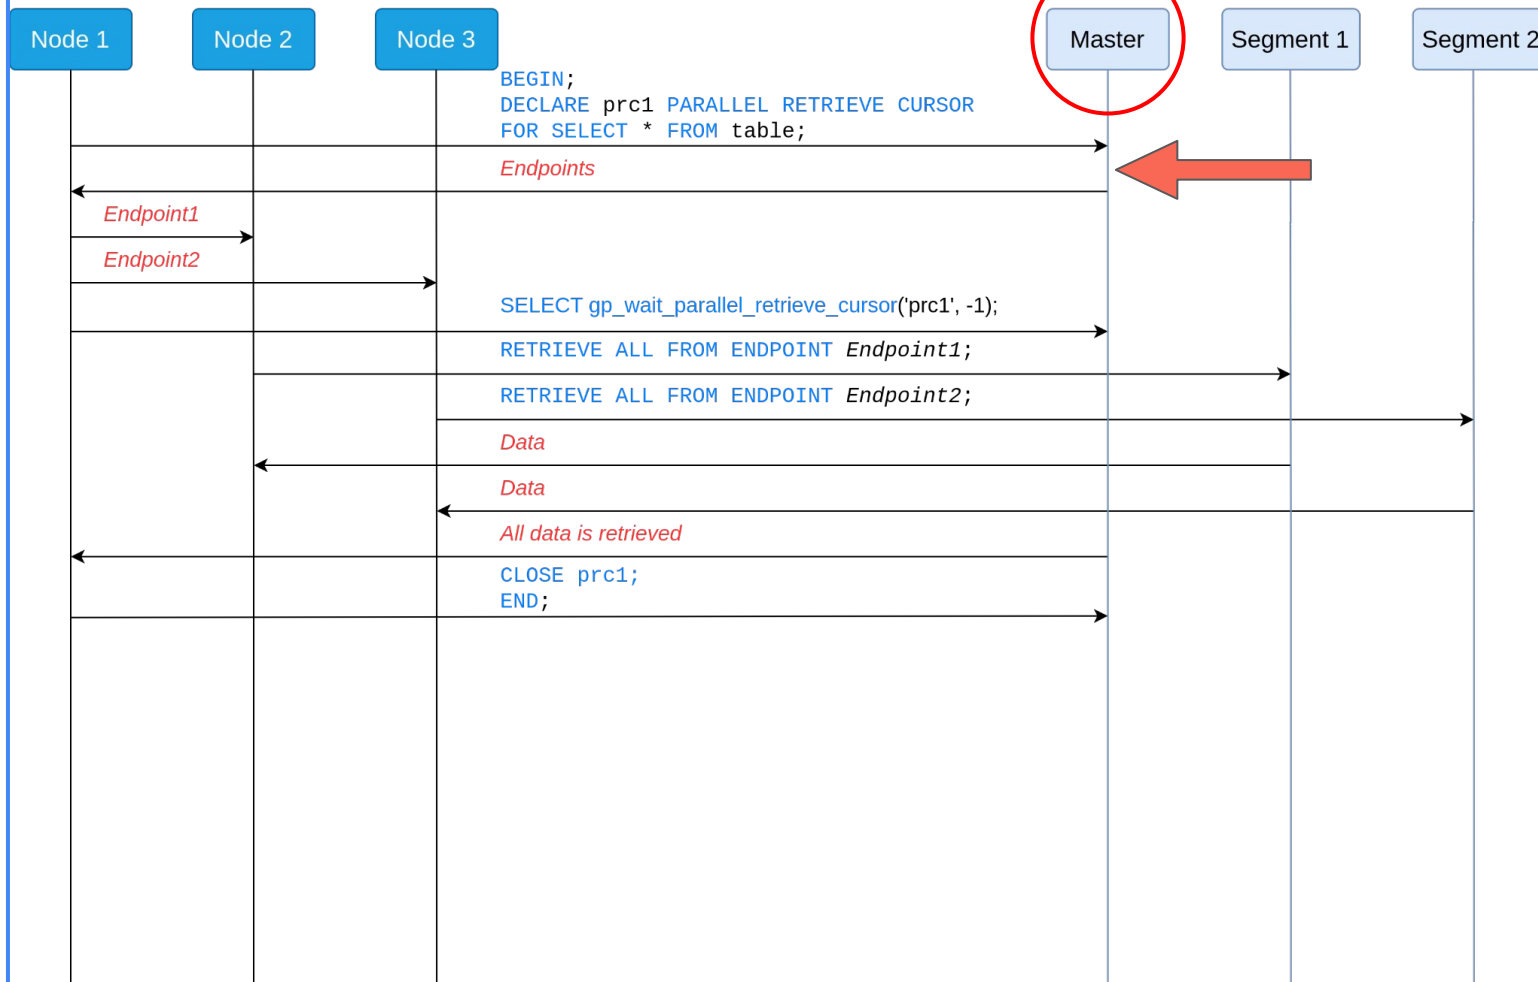


Federated System

Greenplum





121



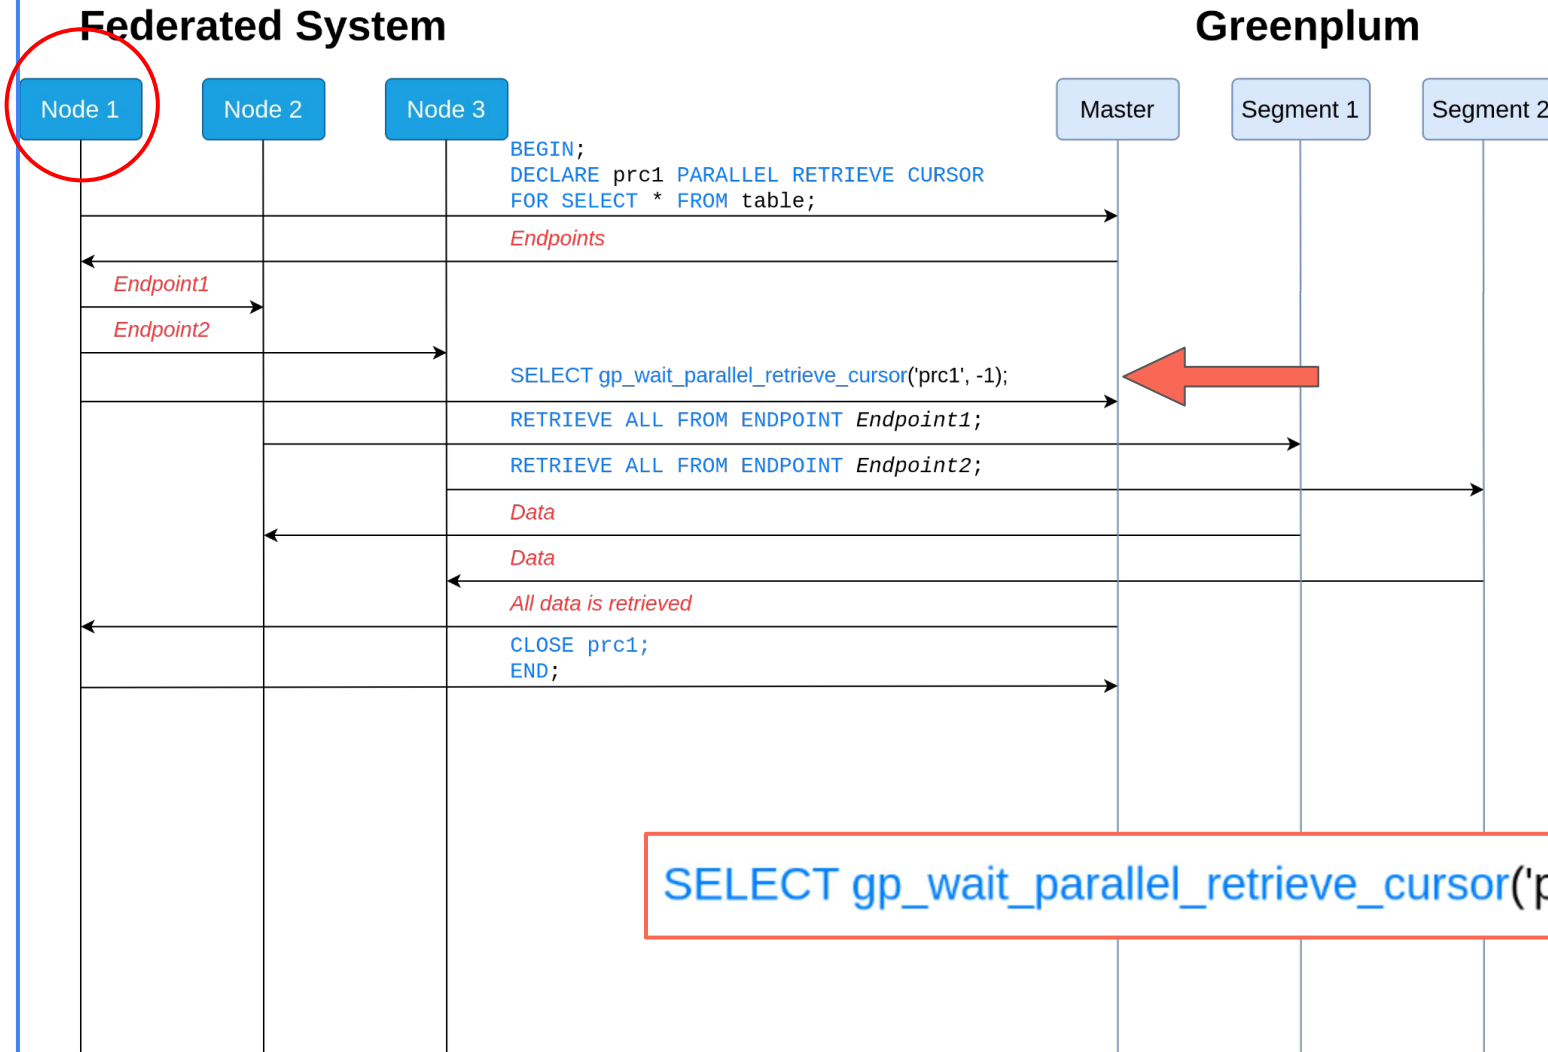
Federated System

Greenplum



Federated System

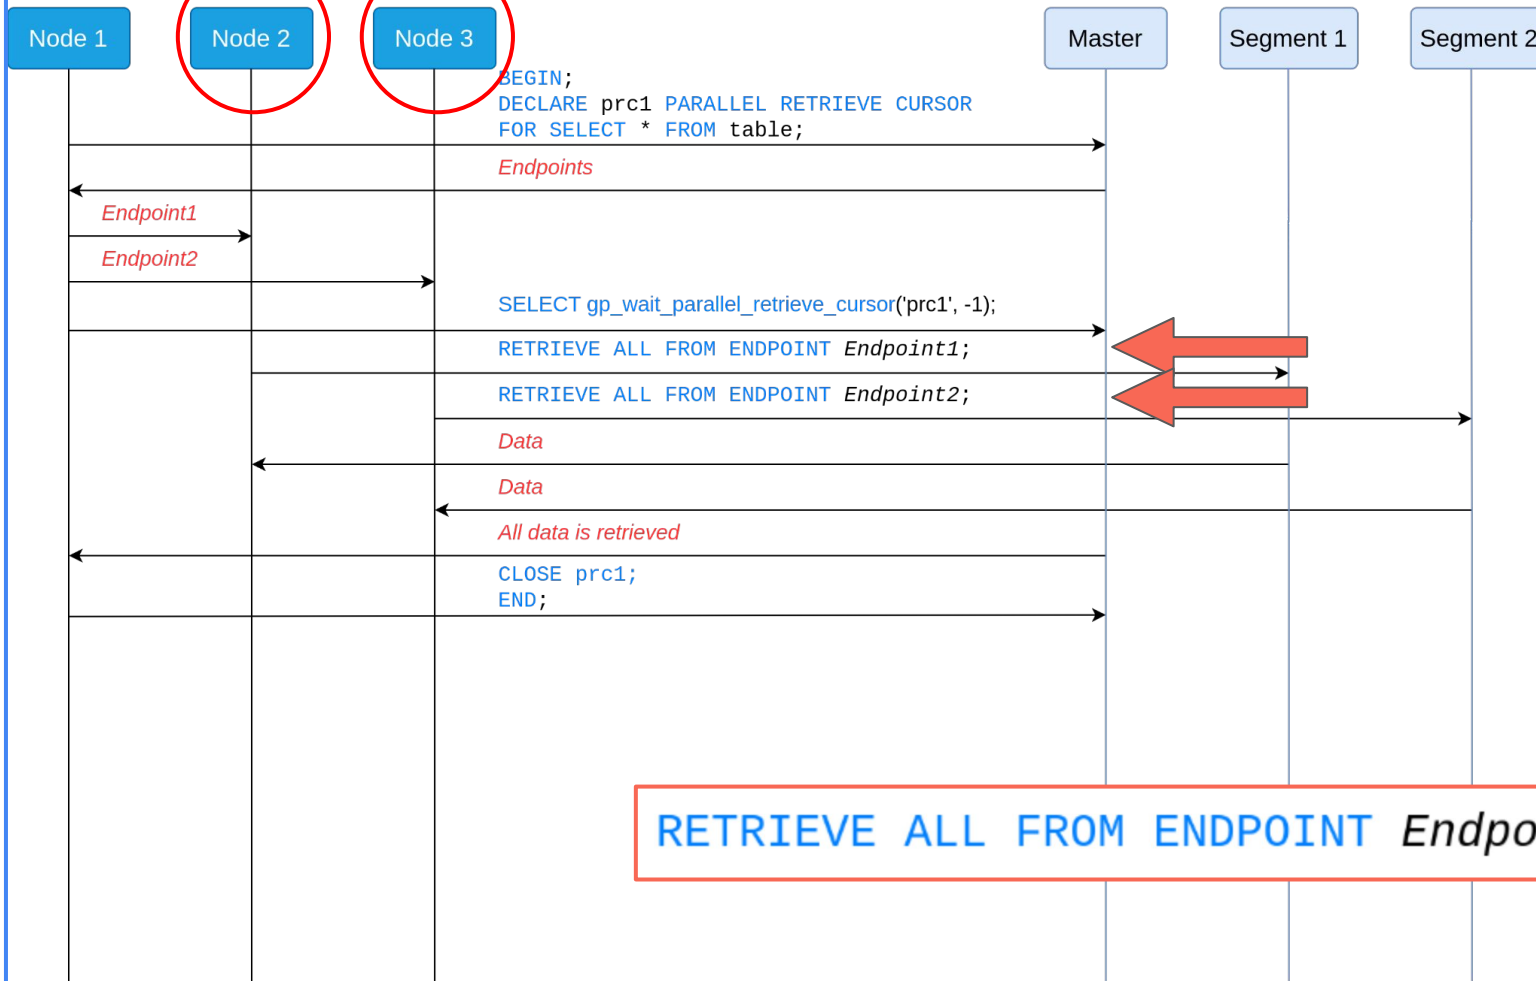
Greenplum



`SELECT gp_wait_parallel_retrieve_cursor('prc1', -1);`


Federated System

Greenplum



Federated System

Greenplum

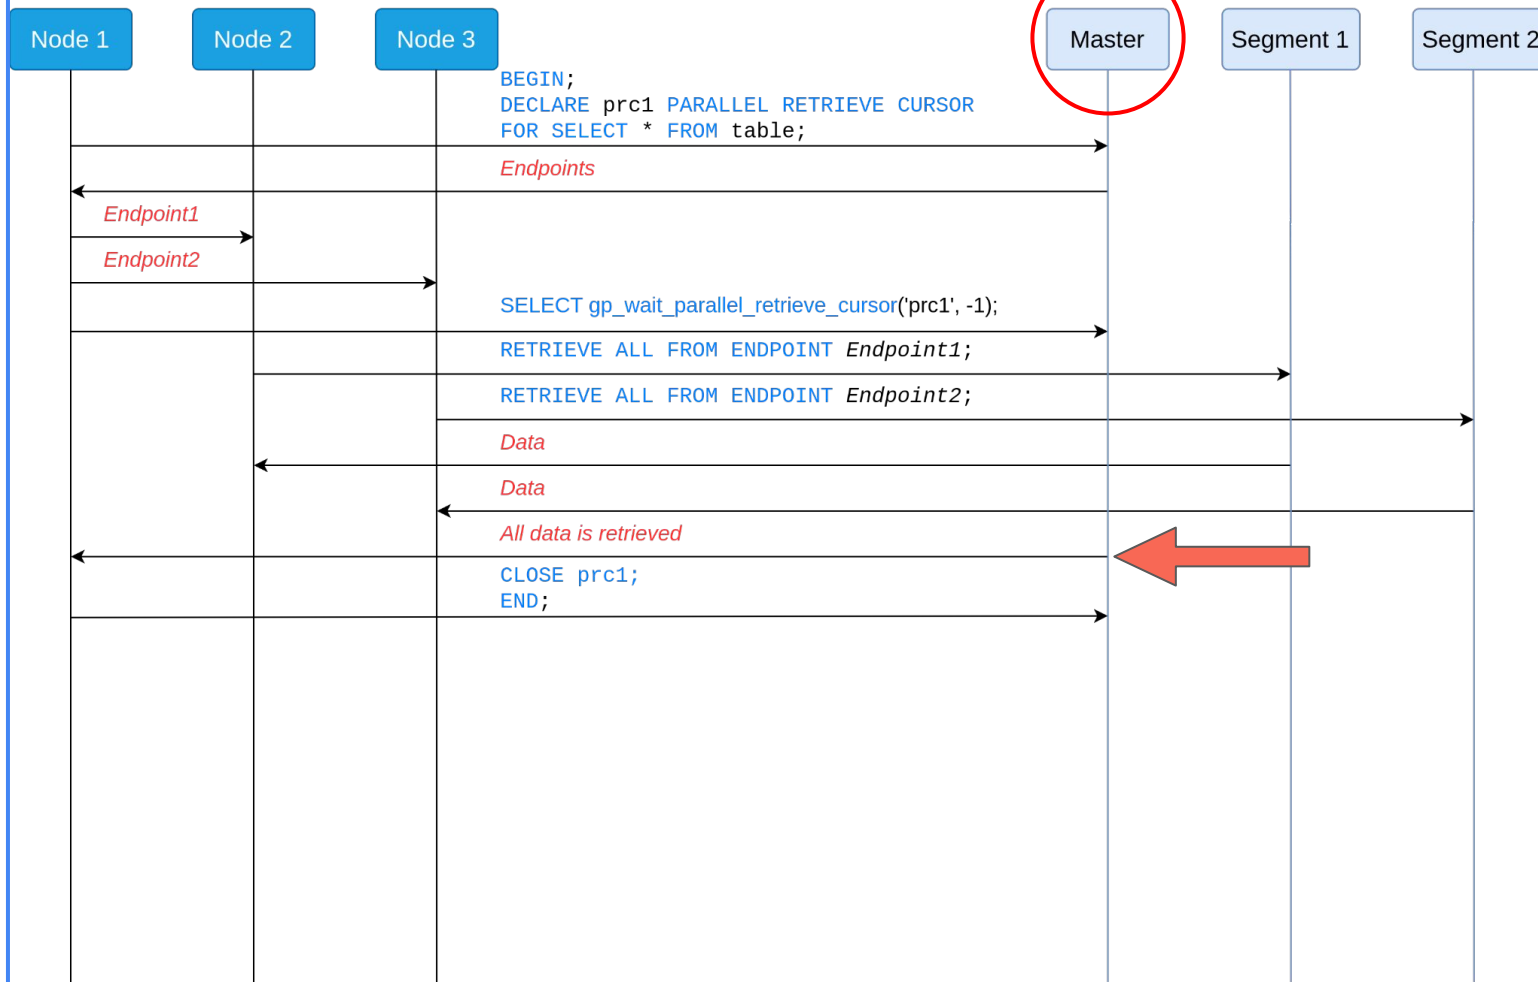


Federated System

Greenplum

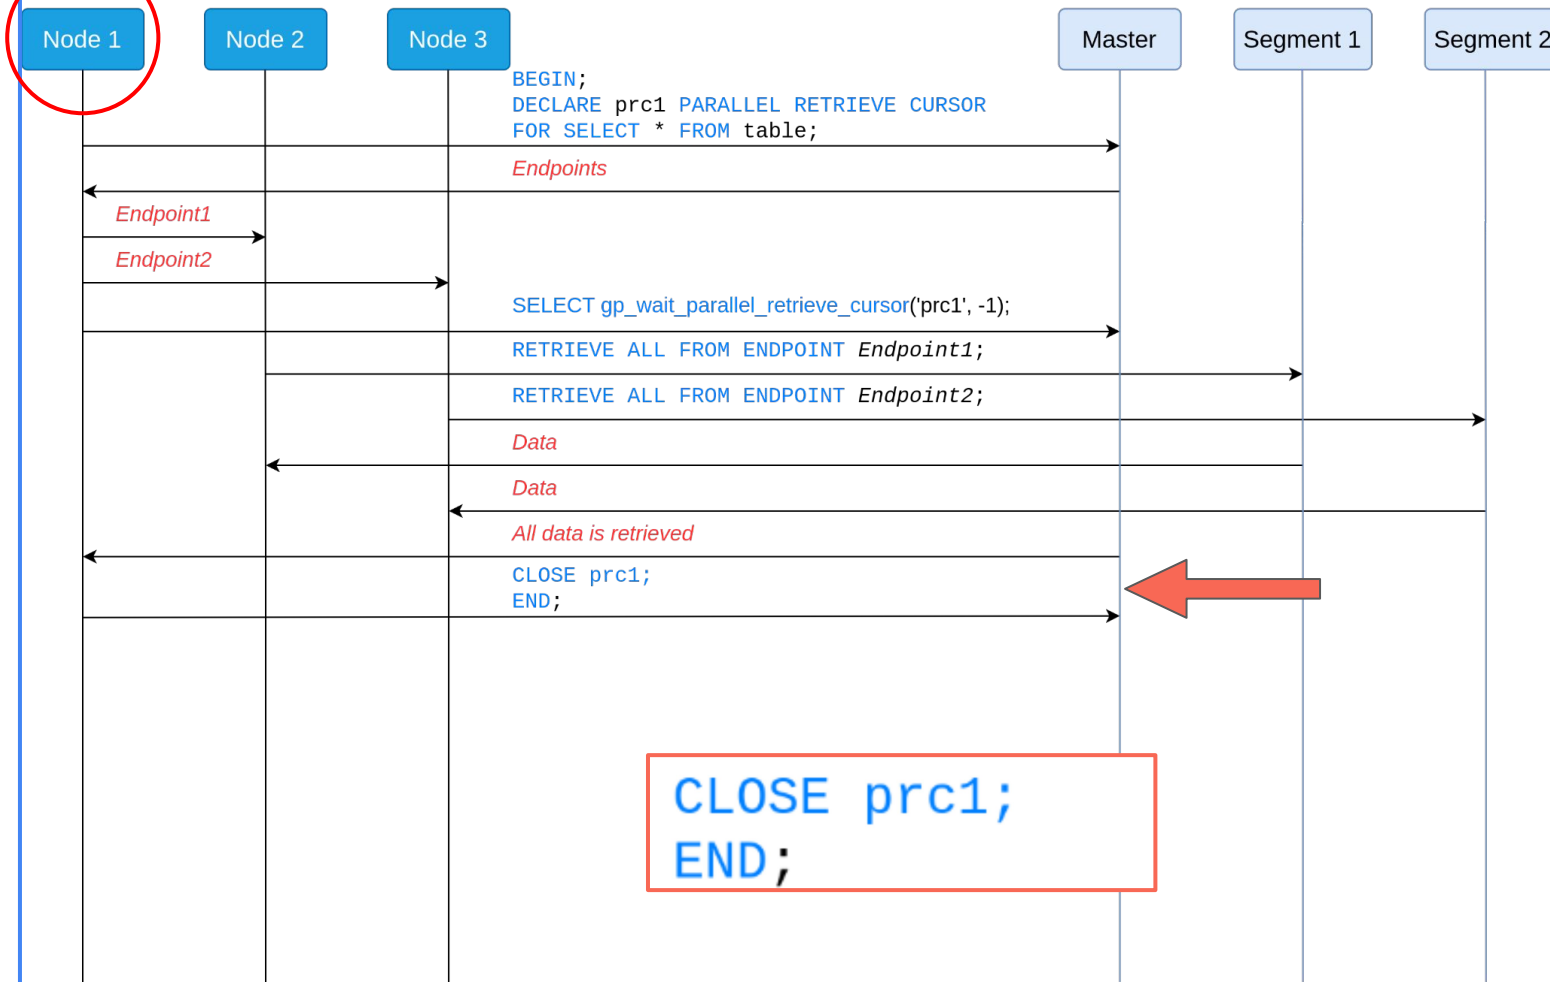


126



Federated System

Greenplum



Консистентное чтение из Greenplum



Плюсы:

- снимоты экспортируемые и глобальные - **гарантия горизонтальной масштабируемости**
- снимот не может устареть

Минусы:

- явная фаза очистки ресурсов
- долгая транзакция на координаторе

Консистентное чтение из ClickHouse



129

Консистентное чтение из ClickHouse



Казалось бы, да:

- под капотом CH использует MVCC и snapshot isolation

Консистентное чтение из ClickHouse

Казалось бы, да:

- под капотом CH использует MVCC и snapshot isolation

Но нет...

- eventual consistency

Консистентное чтение из ClickHouse



132

Казалось бы, да:

- под капотом CH использует MVCC и snapshot isolation

Но нет...

- eventual consistency
- ACID — только для **INSERT**'ов

Казалось бы, да:

- под капотом CH использует MVCC и snapshot isolation

Но нет...

- eventual consistency
- ACID — только для **INSERT**'ов
- **SELECT**'ы могут выдавать дубликаты

Казалось бы, да:

- под капотом CH использует MVCC и snapshot isolation

Но нет...

- eventual consistency
- ACID — только для **INSERT**'ов
- **SELECT**'ы могут выдавать дубликаты
- нет API для экспорта снэпшотов или захвата блокировок

Консистентное чтение из YDB (column tables)



135

Консистентное чтение из YDB (column tables)



136

Казалось бы, да:

- как и в row tables, для всех основных операций поддерживается ACID

Консистентное чтение из YDB (column tables)



137

Казалось бы, да:

- как и в row tables, для всех основных операций поддерживается ACID

Но нет...

- для column tables не реализован механизм копирования таблиц

Сравнение источников данных

Критерий	Классические OLTP				Distributed SQL		Аналитические		
	PostgreSQL	MySQL	MS SQL Server	Oracle	CockroachDB	YDB row table	Greenplum	ClickHouse	YDB column table
Экспортируемые снапшоты (или аналоги)	Да	Нет	Да	Да	Да	Да	Да	Нет	Нет
Глобальные снапшоты (или аналоги)	Нет	Нет	Нет	Иногда	Да	Да	Да	Нет	Да
Возможно устаревание снапшота	Нет	Нет	Нет	Да	Да	Нет	Нет	-	-
Блокировка на запись	Нет	Да	Нет	Нет	Нет	Нет	Нет	-	-
Уведомление координатора о конце чтения и явная очистка ресурсов	Да	Нет	Да	Нет	Нет	Да	Да	-	-
Долгая транзакция на координаторе	Да	Нет	Нет	Нет	Нет	Нет	Да	-	-

Сравнение источников данных

Критерий	Классические OLTP				Distributed SQL		Аналитические		
	PostgreSQL	MySQL	MS SQL Server	Oracle	CockroachDB	YDB row table	Greenplum	ClickHouse	YDB column table
Экспортируемые снапшоты (или аналоги)	Да	Нет	Да	Да	Да	Да	Да	Нет	Нет
Глобальные снапшоты (или аналоги)	Нет	Нет	Нет	Иногда	Да	Да	Да	Нет	Да
Возможно устаревание снапшота	Нет	Нет	Нет	Да	Да	Нет	Нет	-	-
Блокировка на запись	Нет	Да	Нет	Нет	Нет	Нет	Нет	-	-
Уведомление координатора о конце чтения и явная очистка ресурсов	Да	Нет	Да	Нет	Нет	Да	Да	-	-
Долгая транзакция на координаторе	Да	Нет	Нет	Нет	Нет	Нет	Да	-	-
	3	3	4	4.5	5	5	4	0	1

Сравнение источников данных

Критерий	Классические OLTP				Distributed SQL		Аналитические		
	PostgreSQL	MySQL	MS SQL Server	Oracle	CockroachDB	YDB row table	Greenplum	ClickHouse	YDB column table
Экспортируемые снапшоты (или аналоги)	Да	Нет	Да	Да	Да	Да	Да	Нет	Нет
Глобальные снапшоты (или аналоги)	Нет	Нет	Нет	Иногда	Да	Да	Да	Нет	Да
Возможно устаревание снапшота	Нет	Нет	Нет	Да	Да	Нет	Нет	-	-
Блокировка на запись	Нет	Да	Нет	Нет	Нет	Нет	Нет	-	-
Уведомление координатора о конце чтения и явная очистка ресурсов	Да	Нет	Да	Нет	Нет	Да	Да	-	-
Долгая транзакция на координаторе	Да	Нет	Нет	Нет	Нет	Нет	Да	-	-
	3	3	4	4.5	5	5	4	0	1

Сравнение источников данных

Критерий	Классические OLTP				Distributed SQL		Аналитические		
	PostgreSQL	MySQL	MS SQL Server	Oracle	CockroachDB	YDB row table	Greenplum	ClickHouse	YDB column table
Экспортируемые снапшоты (или аналоги)	Да	Нет	Да	Да	Да	Да	Да	Нет	Нет
Глобальные снапшоты (или аналоги)	Нет	Нет	Нет	Иногда	Да	Да	Да	Нет	Да
Возможно устаревание снапшота	Нет	Нет	Нет	Да	Да	Нет	Нет	-	-
Блокировка на запись	Нет	Да	Нет	Нет	Нет	Нет	Нет	-	-
Уведомление координатора о конце чтения и явная очистка ресурсов	Да	Нет	Да	Нет	Нет	Да	Да	-	-
Долгая транзакция на координаторе	Да	Нет	Нет	Нет	Нет	Нет	Да	-	-
	3	3	4	4.5	5	5	4	0	1

Критерий	Классические OLTP				Distributed SQL		Аналитические		
	PostgreSQL	MySQL	MS SQL Server	Oracle	CockroachDB	YDB row table	Greenplum	ClickHouse	YDB column table
Экспортируемые снапшоты (или аналоги)	Да	Нет	Да	Да	Да	Да	Да	Нет	Нет
Глобальные снапшоты (или аналоги)	Нет	Нет	Нет	Иногда	Да	Да	Да	Нет	Да
Возможно устаревание снапшота	Нет	Нет	Нет	Да	Да	Нет	Нет	-	-
Блокировка на запись	Нет	Да	Нет	Нет	Нет	Нет	Нет	-	-
Уведомление координатора о конце чтения и явная очистка ресурсов	Да	Нет	Да	Нет	Нет	Да	Да	-	-
Долгая транзакция на координаторе	Да	Нет	Нет	Нет	Нет	Нет	Да	-	-
	3	3	4	4.5	5	5	4	0	1

ИТОГИ

- Многопоточное и при этом консистентное чтение реализуемо, но между ними существует trade-off.
- **Пользователям СУБД:** проверяйте, есть ли у внешних источников данных глобальные экспортируемые снэпшоты.
- **Разработчикам СУБД:** добавляйте в свои системы глобальные экспортируемые снэпшоты.

TG: @vent_2



**Data
Internals X**
2025